

**ANKARA ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ**

YÜKSEK LİSANS TEZİ

**DÖNER KANATLI İNSANSIZ HAVA ARAÇLARI İLE GÖRSEL VERİLERE
DAYALI ERKEN YANGIN ALGILAMA SİSTEMİ**

Ayşegül DEMİRTAŞ

BİLGİSAYAR MÜHENDİSLİĞİ ANABİLİM DALI

**ANKARA
2019**

Her hakkı sakıldır

ETİK

Tez içindeki bütün bilgileri akademik yazım kurallarına uygun biçimde raporlaştırdığımı ve bunları etik ilkelere (atıfta bulunulan tüm yapıtlara kaynaklarda yer verilmesi, tezde kullanılan bilgi ve belgelere resmi yollarla ulaşılması ve bunların aslı bozulmadan kullanılması vb.) uygun olarak elde ettiğimi ve sunduğumu bildiririm.

26/09/2019

Ayşegül DEMİRTAŞ

ÖZET

Yüksek Lisans Tezi

DÖNER KANATLI İNSANSIZ HAVA ARAÇLARI İLE GÖRSEL VERİLERE DAYALI ERKEN YANGIN ALGILAMA SİSTEMİ

Ayşegül DEMİRTAŞ

Ankara Üniversitesi
Fen Bilimleri Enstitüsü
Bilgisayar Mühendisliği Anabilim Dalı

Danışmanı: Doç. Dr. Mehmet Serdar GÜZEL

Bu makalede, orman yangınlarını erken algılama sistemlerine, görsele dayalı, yeni ve kesinliği artırılmış bir bakış açısı getirmek hedeflenmektedir. İnsansız hava araçları teknolojilerinden faydalanılarak geliştirilen sistemlerin sayısının gün geçtikçe arttığı bu dönemde, dünyanın ciğerleri olan ormanlarımızın doğal akışın dışında tahribatının en aza indirilmesi ve bu yolda işgücü ve zaman kaynaklarının en iyi şekilde yönetilmesi hedeflerine ulaşmak için, görü yetisi kazandırılmış insansız hava araçlarının kullanılması yerinde olacaktır. Tez konusu doğrultusunda yürütülen uygulama sonucunda, insansız hava aracı ile duman görselinin tespitine dayalı sistemin yangın algılamada meydana gelen hata oranını azaltılmasında büyük ölçüde fayda sağlayabileceği öne sürülmektedir.

Sistemdeki mikrodenetleyici, derin öğrenme metodları ile eğitilerek programlanmış insansız hava aracına yangın tanısının en erken bulgusu olan duman görselini tanıyabilme yetisi kazandırılmıştır. Yangın tespitinde kullanılan yaygın algoritmalarda en temel problem olan asılsız ihbar ve gözden kaçırma oranlarının yüksek olmasıdır. Alınan görselden çıkarılan sonucun teyit edilmesi ve fazladan bir sağlama aşaması tanımlanması sistemin güvenilirliğini arttıracak gibi sonucun kesinliğini de garantileyecektir. İnsansız hava aracının mobil görü sağlaması sayesinde veriler yerinden, net ve sürekli alınabilecek kontrol noktası tarafından görüş açısı kontrol edilebilecektir. Makale konusu doğrultusunda geliştirilen uygulama simülasyon ortamında gerçekleştirilmiş ve analiz sonuçlarıyla erken yangın algılama sisteminin sağladığı avantajlar makalenin sonuç bölümünde işlenmiştir.

Eylül 2019, 78 sayfa

Anahtar Sözcükler: Raspberry Pi Projeleri, Dron/İnsansız Hava Aracı Projeleri, Nesne Tanıma/Algılama, Evrişimli Sinir Ağları, Denetimli Derin Öğrenme

ABSTRACT

Master Thesis

VISUAL BASED EARLY FIRE DETECTION SYSTEM WITH UNMANNED AERIAL VEHICLES

Ayşegül DEMİRTAŞ

Ankara Universtiy

Graduatde School of Natural anda Sciensec
Department of Computer Engineering

Supervisor: Assoc. Prof. Dr. Mehmet Serdar GÜZEL

In this article, it is aimed to bring a new and improved perspective based on visual indications relating to early detection systems in forest fires. In this period where the number of systems developed by utilizing unmanned aerial technology is increasing day by day, unmanned aerial vehicles will be used to achieve the targets of minimizing the destruction of our forests which are the lungs of the world and optimizing the usage of workforce and time resources. As a result of the application carried out in line with the subject of the thesis, it is proposed that the system based on the detection of a smoke image with an unmanned aerial vehicle can provide a great benefit in reducing the error rate occurring in fire detection.

The microcontroller in the system has been trained with deep learning methods and has been given the ability to recognize a smoke image, which is the earliest sign of fire diagnosis. The most fundamental problem in the common algorithms used in fire detection is the high level of false alarm and overlook rate. Confirming the result obtained from the detection and defining an additional proof will increase the reliability of the system as well as the accuracy. Since the unmanned aerial vehicle provides a mobile vision, the point of view can be controlled by the ground station can manipulate it for the sake of the accuracy of the result. The application developed in line with the subject of the article was implemented in a simulation environment and the advantages of the early fire detection system and analysis are discussed in the conclusion section of the article.

Septeber 2019 78 pages

Key Words: Raspberry Pi Projects, Drone/Unmanned Aerial Vehicle Applications, Object Detection/Perception, Artificial Neural Networks, Supervised Deep Learning

TEŞEKKÜR

Başta saygıdeğer tez danışmanım Doç. Dr. Mehmet Serdar GÜZEL olmak üzere, danışmaya ve fikirlerini almaya gittiğimde kıymetli vakitlerini ayıran tüm Ankara Üniversitesi Bilgisayar Mühendisliği bölümü akademik kadrosu üyelerine teşekkürü borç bilirim.

Yalnızca tez yazım sürecinde değil hayatımın her evresinde maddi ve manevi desteğini, dualarını ve sevgisini, tıkanığım ve devam etmeye gücümün kalmadığını hissettiğim anlarda inancını esirgemeyen sevgili annem Mübeccel DEMİRTAŞ ve babam Aydın DEMİRTAŞ'a sonsuz teşekkürlerimi sunarım.

İnsansız hava araçları ile olan yolculuğumuz boyunca bana bazen yol arkadaşı bazen yol gösteren olan, kendisinden çok şey öğrendiğim ve ömrüm boyunca yanımda olmasını kalpten dilediğim sevgili nişanlım Mertkan YANIK'a ve yıllardır emeği ve sevgisiyle aile özlemine bana yaşatmayan, tanıştığımız ilk günden bu yana benim için sevgi dolu bir anne olan sevgili Sema ERHAN'a sonsuz teşekkürlerimi sunarım.

Ankara, Ekim 2019

Ayşegül DEMİRTAŞ

İÇİNDEKİLER

TEZ ONAY SAYFASI	
ETİK.....	i
ÖZET.....	ii
ABSTRACT	iii
TEŞEKKÜR	iv
SİMGELER DİZİNİ	vi
ŞEKİLLER DİZİNİ	vii
ÇİZELGELER DİZİNİ	ix
1. GİRİŞ.....	1
1.1 Motivasyon.....	1
1.2 Arkaplan ve Literatür Taraması	2
1.2.1 Sistem tasarımı mimarisi ve gereksinimleri	3
1.2.2 Literatürde insansız hava aracı sistemleri.....	4
1.2.3 Görsele dayalı yangın algılama sistemleri	8
1.3 Problem Formülasyonu	16
1.4 Tezin Hedefi.....	19
1.5 Tezin Organizasyonu	20
2.KURAMSAL TEMELLER.....	21
2.1 Veri Kümelerinin Oluşturulması.....	22
2.2 Kamera Ve Görüş Açısı Değişkenlerinin Değerlendirilmesi.....	22
3. METERYAL VE YÖNTEM.....	23
3.1 Tensorflow Kütüphanesi	25
3.1.1 Tensorflow çalışma prensibi	25
3.1.2 Tensorflow ile nesne tanıma.....	27
3.2 Raspberry Pi 3 Model B+	27
3.2.1 Raspberry pi kurulumu	29
3.2.2 Uzaktan raspberry kontrol	37
3.2.3 Raspberry ile insansız hava aracı entegrasyonu	42
4. ARAŞTIRMA BULGULARI	44
4.1 İnsansız Hava Aracı Tasarımı	45
4.2 İnsansız Hava Aracının Modellenmesi.....	48
4.3 İnsansız Hava Aracının Yazılım Boyutu.....	49
5. TARTIŞMA VE SONUÇ	50
KAYNAKLAR	70
EK 1 Tasarım Şemaları	75
ÖZGEÇMİŞ	78

SİMGELER DİZİNİ

ESA	Evrişimli Sinir Ağları
YSA	Yapay Sinir Ağları
İHA	İnsansız Hava Aracı
İHAS	İnsansız Hava Aracı Sistemi
TF	Tensorflow
IR	Infrared
RGB	Red, Green, Blue : Kırmızı, Yeşil, Mavi Renk Uzayı
HSL	Derinlik, Doygunluk, Aydınlık Renk Uzayı
HSV	HSL ve RGB Değerlerinin Birlikte İfade Edildiği Renk Uzayı
YUV	Renk değerinin UV ikilisiyle ifade edildiği Renk Uzayı
Binary	İkili İfade
EAA	Etki Alanı Adaptasyonu
FlickerAPI	Bir Sosyal Paylaşım Aplikasyonu
3D	Üç Boyutlu
IoT	(Internet of Things) Nesnelerin interneti
LiPo	Lityum Polimer
AGL	Zemin seviyesi (Above Ground Level)

ŞEKİLLER DİZİNİ

Şekil 3.1 Projede kullanılan SD Kart ve Temsili ve Kart Adaptörü Temsili	29
Şekil 3.2 SD Karta Önyüklenabilir ISO İmajı Yüklemeye Yarayacak Win32Disk Imager Program Çalışır Görüntüsü	31
Şekil 3.3 Raspberry Pi Micro SD Card Girişinde Önyükleme için Hazırlanmış Olan Kart.....	32
Şekil 3.4 Raspberry Pi Modülü ve Ek Programlama Araçları	33
Şekil 3.5 Raspbian İşletim Sistemi Kurulum Seçenekleri	34
Şekil 3.6 Kamera Modülü Bağlantı Şekli	35
Şekil 3.7 Raspberry Konfigürasyon Ayarları Arayüz Görünümü.....	36
Şekil 3.8 Raspberry Pi Giriş ve Çıkış Bileşenleri	38
Şekil 3.9 Dönüştürücü Kablo ile RPi GPIO Pinlerinin Eşleşme Biçimi.....	39
Şekil 3.10 Raspberry Pi GPIO Pinleri Dizilim Şeması	40
Şekil 3.11 Putty Konfigürasyon Arayüzü	41
Şekil 3.12 Batarya Ayarlayıcı Devre Dönüştürücüsü ve BEC Devresinin Bağlanacağı Raspberry Pinleri.....	43
Şekil 4.1 (solda)Projede Kullanılan İnsansız Hava Aracının 3D SOLIDWORKS Modeli ve (sağda) aracın son hali	48
Şekil 5.1 Derin Öğrenmede Ön İşleme Aşamasında Kullanılan LabelImg Programı	51
Şekil 5.2 (solda) Modelin Eğitim Aşamasında Tensorboard Sunucusunda Meydana Gelen (sol üstten, sağ alta sırasıyla) Oluşan (a)Sınıflandırma Kaybı, (b)Yerleştirme Kaybı,(c) Toplam Kayıp ve (d) Devamlılık Kaybı Grafikleri	52
Şekil 5.3 Özelleştirilmiş Yeni Modelin Entegrasyonu.....	53
Şekil 5.4 Yeni Modelin Duman Görselini Değerlendirmesi.....	54
Şekil 5.5 (solda)Masaüstünde Çalışan Modelin(ssd_mobilenet) Kumanda Doğruluk Oranı ve (sağda) Raspberry Pi Üzerinde Modelin (ssdlite_mobilenet) Kumanda Doğruluk Oranı.....	55
Şekil 5.6 (solda) Masaüstünde Çalışan Modelin(ssd_mobilenet) Cep Telefonu Doğruluk Oranı ve (sağda) Raspberry Pi Üzerinde Modelin (ssdlite_mobilenet) Cep Telefonu Doğruluk Oranı	56
Şekil 5.7 (sol üstten sağ aşağı sırasıyla)(a)%60 Eğitim %40 Test Verisi Üzerinde Eğitilen Model M4, (b)%80 Eğitim %20 Test Verisi Üzerinde Eğitilen Model M3, (c)%70 Eğitim %30 Test Verisi Üzerinde Eğitilen Model M2, (d)%90 Eğitim %10 Test Verisi Üzerinde Eğitilen Model M1 eğitilirken gözlemlenen Tensorboard Sınıflama Kayıp Grafikleri	57

Şekil 5.8 (sol üstten sağ aşağı sırasıyla)(a)%60 Eğitim %40 Test Verisi Üzerinde Eğitilen Model M4, (b)%80 Eğitim %20 Test Verisi Üzerinde Eğitilen Model M3, (c)%70 Eğitim %30 Test Verisi Üzerinde Eğitilen Model M2, (d)%90 Eğitim %10 Test Verisi Üzerinde Eğitilen Model M1 eğitilirken gözlemlenen Tensorboard Yerleştirme Kayıp Grafikleri.....	58
Şekil 5.9 (sol üstten sağ aşağı sırasıyla)(a)%60 Eğitim %40 Test Verisi Üzerinde Eğitilen Model M4, (b)%80 Eğitim %20 Test Verisi Üzerinde Eğitilen Model M3, (c)%70 Eğitim %30 Test Verisi Üzerinde Eğitilen Model M2, (d)%90 Eğitim %10 Test Verisi Üzerinde Eğitilen Model M1 eğitilirken gözlemlenen Tensorboard Toplam Kayıp Grafikleri	59
Şekil 5.10 Kontrol Grubu.....	62
Şekil 5.11 Test Uçuşundan Bir Kare.....	66
Şekil 5.12 Test Uçuşunda Pilot Aracın Bakış Açısını Ayarlamaya Çalışıyor	67
Şekil 5.13 Hareket Halindeki Araca Entegre Çalışan Raspberry Cihazında Gerçek Zamanlı Video Girdisi Üzerinde Yürütülen Duman Tanıma Modelinin Çıktı Görüntüleri	68

ÇİZELGELER DİZİNİ

Çizelge 1.1 İnsansız Hava Araçlarının Sınıflandırılması.....	7
Çizelge 4.1 Sitesinden Alınan Avroto 2814-11s Test Verileri	47
Çizelge 5.1 Model Zoo Alt Modellerinin Hız ve Doğruluk Karşılaştırması	50
Çizelge 5.2 Kontrol Grubu Üzerinde Yürütülen Dört Modelin Çıktı Sonuçları.....	61
Çizelge 5.3 Kontrol Grubu Üzerinde Yürütülen Dört Modelin Tahmin Değerleri	63
Çizelge 5.4 Kontrol Grubu Üzerinde Yürütülen Dört Modelin Karşılaştırılması.....	65

1. GİRİŞ

Yangın görseli gerçek zamanlı akış içerisinde incelendiğinde gerek devinimi, gerek içerdiği renk spektrumu, gerekse dokusal yapısı itibariyle bariz ayırt edici özellikler taşımaktadır. Bu niteliğiyle çeşitli filtreleme, kenar bulma, renk tanıma gibi araçlar yardımıyla gökyüzündeki ve ormandaki diğer doğal bileşenlerden kolayca ayrıştırılabilmektedir. Ancak ateş ve alev görülebilir hacme geldiğinde müdahale için hayli geç kalınmaktadır. Bu sebeple yangının daha erken bulgusu olan duman verisinden yola çıkarak yangın tanısına kanaat getirmek daha hızlı reaksiyon alınmasının önünü açacaktır.

1.1 Motivasyon

Günümüzde geliştirilen uygulamalarda görüntü veya video girdisinin görüntü işleme algoritmalarıyla işlenmesinden elde edilen sonuçları yüksek oranda hatalar içermektedir. Yangın olan durumda sinyal verilmemesi veya yangın olmadığı halde sistemin alarm durumuna geçmesi hata olarak nitelendirilen durumlardır. Yangın algılama sistemlerinde hata oranının yüksek olmasının neticesinde, iş gücü ve zaman kaybının yanı sıra kurtarılabilecek yeşil alanın boyutu önemli ölçüde azalabilmektedir. Erken ve yerinde müdahale için hata durumları en aza indirgenmelidir. Bu aşamada insansız hava araçları ile belirli periyotlarda devriye gezen bir kontrol sistemi, yangının sağlamlasının yapılması ve daha net görü sağlanması açısından fonksiyonel olacaktır.

İnsansız hava araçlarının güç bileşeninden regüle edilen elektrikle beslenebilen bir mikrodenetleyici tercihi ile araçtan alınan verilerin araç içindeki cihazda, Tensorflow kütüphanesi kullanılarak duman görseli tespiti için yapay öğrenme yoluyla eğitilmesi, yangın ihtimalinin değerlendirilmesi aşamasında zaman tasarrufu sağlayacaktır. Bu çalışmada yanlış ihbar ve gözden kaçırma oranını minimize ederek süreci en verimli hale getirmek en temel amaçtır.

1.2 Arkaplan ve Literatür Taraması

Tez çalışma sürecine başlarken, tez konusunun belirlenmesinin ardından öncelikle insansız hava araçları ile ilgili teorik kaynaklar incelenmiş, edinilen bilgiler doğrultusunda bu alanda uygulamalar geliştiren kişilerle temas haline geçilerek bu kişilerin tecrübeleri ışığında tez projesinde kullanılacak insansız hava aracı meydana getirilmiştir. Aracın gövde tasarımı özgün ve elektronik aksamındaki bileşenleri görev yönelimli olarak özelleştirilmiştir. Yazılımsal ve donanımsal olarak aracın sistemle uyumlu çalışması ve verilen görevleri en az hata oranı ile tamamlayabilmesi için kullanılması gereken yol ve yordama karar verme sürecinde insansız hava araçlarıyla ve araçların beyni olarak kullanılagelen mikrodenetleyicilerle ilgili çeşitli kaynaklar araştırılmış ve etraflıca incelenmiştir. Yayın olarak erişilebilen kaynaklardan, yürütülecek projedeki duman tanıma görevine benzer görünüş işleme, nesne tanıma, duman algılama yazılımları ile ilgili olanlar analiz edilmiştir. Analiz sonucu ilişkili ve faydalı görülen kaynaklar, literatür taraması kısmında detaylandırılmıştır.

Literatür araştırması, gerçekleştirilecek uygulamanın benzerlerinin bulunması ve uygulamada kullanılan yazılımsal bileşenlerle, aracı meydana getiren donanımsal parçaların seçimi hususunda tercih edilen öğelerin gerekçelendirilmesi ve öngörülemez kayıpların ve tahmin yoluyla saptanması güç iyileştirmelerle çalışmayı hızlandırması açısından bu çalışmada çok önemli rol oynamaktadır. Projede kullanılan her modül, hizmet etmekte olduğu amacın dışında farklı pek çok işleve sahip olduğundan, her bir unsurun kullanım alanı, muadilleri ile kıyaslandığında gözlemlenen üstünlükleri ve noksanlıkları, kapasitesi ve limitleri ve tüm bunların yanında projedeki isterlerle örtüşme durumu analiz edilmeli ve eğer varsa gerekli güçlendirmeler ve tamamlayıcı eklentilerle sistemin bütünlüğü teorik olarak kesinleştirildikten sonra parçaların temin edilerek kullanmaya hazır hale getirilmesi, maliyeti yüksek bu projede israfın ve başarısızlık durumlarının en aza indirilmesinde tamamlanması gereken önemli bir ön aşamadır. Arkaplan ve literatür araştırması sonucunda edinilen bulguların proje ile ilişkisinin kurulması ve literatür analiziyle yalnızca proje ile doğrudan ilişkili sonuçlara makalede yer verilmesi uygun bulunmuştur.

1.2.1 Sistem tasarımı mimarisi ve gereksinimleri

İnsansız hava aracı teknolojileri sürekli olarak gelişmekte ve gün geçtikçe yeni bir boyut kazanmaktadır. Günümüzde insansız hava araçları işlevlerine göre hedef yem, keşif gözetleme, çatışma, lojistik, araştırma ve geliştirme, sivil ticari gibi sınıflara ayrılmaktadır. Teknik açıdan bakıldığında ise bu araçlar motor sayısına, kanat tipine veya gövde kasa tipinin şekline göre kategorilere ayrılabilir. Her bir küme kendi içinde ortak özellikler barındırsa da bir kümeye dahil araçların her biri kendine has bazı niteliklere de sahiptir. Bu nitelikleri meydana getiren bileşenler tercih edilirken aracın gerçekleştirmesi beklenen görev baz alınarak uygun parçaların seçilmesi ve doğru kompozisyonda birleştirilmesi önemsenir.

Tez projesi olan insansız hava araçlarıyla yangın algılama sisteminin bileşenleri, yapay öğrenme algoritması ile duman görselini ayırt etmek üzere programlanmış Raspberry Pi 3 model B+ mini bilgisayar ile donanmış, dört döner kanatlı X kasa tipli insansız hava aracı, yer kontrol birimi ve yangın müdahale biriminden meydana gelmektedir. Bu sistemde kontrol birimi insansız hava aracının devriye kontrolleri sırasında rapor verdiği ve duman görseline rastladığı durumlarda alarm sinyali ilettiği bir ana bilgisayar ve alarm durumunu yangın birimine iletecek bir operatörü ifade etmektedir. Yangın birimi ise itfaiye teşkilatı ve ilgili itfaiye birimi çalışanlarını ifade eder.

Kamu yararına yürütülecek doğa dostu bu projenin hayata geçirilmesi için veya test platformunun oluşturularak yangın olma durumu ve yangın olmama durumu senaryolarının yaratılabilmesi için maddi ve bürokratik desteğe ihtiyaç duyulmuştur.

Proje aracı orman üzerinde devriye gezerek yangın olan bölgedeki dumanı gerçek zamanlı işleme donanımına sahipse de bunu küçük bir alanda çıkarılan kontrollü yangın simülasyon ortamı üzerinden uçurulan insansız hava aracı ile duman görselini tespit etme teşebbüsleri sınanmış ve sonuçlar tez çalışmasına yansıtılmıştır. Simülasyon çalışması her ne kadar tez çalışmasına matematiksel sonuçların eklenebilmesi için gerçekleştirilmişse de, suni ortamda kontrollü çıkarılan bir yangından tüten dumanın renk, doku ve boyut bakımından gerçeğine muadil olamayacağı unutulmamalıdır.

Önce toplanan çam kozalaklarının yakılmasıyla elde edilen duman, gün ışığında çok cılız ve yetersiz kaldığından kamera tarafından saptanamamış, sonra çalı çırpı, plastik nesneler ve mangal jeli yardımı ile yeterli görünürlükte duman elde edilebilmiştir. Doğa tahribatına karşı geliştirilen bu uygulamada, doğaya zarar verme riski bulunan hiçbir hamle göze alınmamıştır, çıkarılan yangın ve kalıntıları söndürülmüş ve temizlenmiştir. Bu testin sonuçları da yine tez çalışmasının sonuçlar bölümünde yer almaktadır. Kontrollü yangın üzerinden yürütülen test ortamı sonuçları ile duman fotoğrafları üzerinden çalışan programın test edilmesi sonucunda elde edilen doğruluk ve hata oranı yine çalışmanın sonuçlar bölümünde kıyaslanmış ve karşılaştırılmıştır.

Kontrollü test ortamı kurulmadan önce, donanımsal ve yazılımsal özellikleri belirtilen insansız hava aracı sistemi çalışır hale getirilmiş; Raspberry Pi modülü aracın üzerinde aracın güç ünitesinden beslenecek şekilde araçla uyum içinde çalışır hale getirilmiş; işlemci modülüne Tensorflow, lxml, protobuf, OpenCV gibi kütüphaneleri çaışmaksızın çalışacak versiyonlarda yüklenmiş ve modül, insansız hava araçlarıyla alınan görsel veri kümesindeki etiketli fotoğraflar kullanılarak duman görselini ayırt edecek hale gelene dek eğitilmiş; Raspberry'nin uyumlu kamerası Raspberry Pi V2 Kamera ile alınan gerçek zamanlı veri üzerinden çalışır hale getirilerek bir takım deneme çalışmaları yürütülmüş; böylece test öncesi yürütülebilecek adımların tamamlanmasıyla sistem kontrollü test ortamında sınanmaya hazır hale getirilmiştir.

Bu çalışmada, benzer projelerde basamak olması açısından faydalı olabilecek ip uçlarına ve sürdürülmesi gereken adımlara yer verilmiştir. Sunulan test sonuçları ve bileşenlerin bir arada ortaya koydukları performans analizi ile benzer çalışmalar yapmak isteyen bilim insanlarına yol gösterebilecek verilere, sonuçlara ve karşılaştırmalara yer verilmiştir.

1.2.2 Literatürde insansız hava aracı sistemleri

İnsansız hava aracı denildiğinde, projeden bağımsız bilimsel çalışmaların (Gao & Cheng, 2019) büyük ölçüde insansız hava araçlarının tarihteki gelişimi, insansız hava aracı kullanımındaki yasal regülasyonlar ve araçların sınıflandırması üzerine çalışmalar yapıldığı gözlemlenmiştir. Sivil amaçlı kullanım alanı çerçevesinden bakılacak olursa

insansız hava araçlarının gelişimi ve topluma kazandırılması son birkaç yıllık çalışmalarda hız kazanmıştır. Elektronik ve mekanik disiplinlerin bir arada çalışmasının ürünü olan bu araçların programlanmasıyla görü, otonom uçuş, sistematik atış mekanizması, labirentte yol bulma gibi problem çözme, diğer araçlarla iletişim ve sürü mantığıyla işbirlikçi rotasyon ve oryantasyon yetileri kazandırılarak insansız hava araçları pek çok görevde verimli ve etkili biçimde kullanılmaya başlandı.

Havacılık, hata toleransı en az olan alanlardan biridir. İnsanlı araçlarla kıyaslandığında, uygulamalarda kullanımı bakımından insansız hava araçları az maliyetli, yüksek doğruluk oranıyla zaman tasarrufu sağlayan araçlardır. 18. yüzyıldan bu yana dünya literatüründe varlığını gösteren bu araçların, günümüzde yeni yeni yaygınlaşmasının temel nedeninin insansız hava araçlarının ilk kullanım alanının saldırı ve bombalama amaçlarına hizmet ediyor olması olduğu savunulmaktadır.

Bombacı balonlardan füzelere uzanan geniş bir yelpazede patlayıcı tahribat aracı olarak kullanılan bu araçların, toplum nezdinde yarattığı olumsuz çağrışımları yıkması ve haritacılık, çevresel gözlem, hava durumu izleme, kirlilik tespiti, yangın izleme, tarımsal uygulamalar, kentsel dönüşüm çalışmaları, arkeolojik çalışmalar gibi sivil/bilimsel projelerde kullanımı ve hatta gündelik yaşamda hobi amaçlı kullanımı ve erişilebilirliğinin artması, bu alanda yürütülen araştırma geliştirme projelerine ivme kazandırmıştır ve bu araçlarla yürütülen görevlerden büyük ölçüde verim alınmaktadır. Literatürde insansız hava aracı, insansız hava aracı sistemleri ve dron kelimelerinin ifade ettiği kavramlar tanımlanmış ve bu kavramların benzer ve farklı yönleri üzerinde durulmuştur.

Özetle, dron kelimesi ilk kullanılan insansız hava araçlarını ifade etmekteydi ve daha çok askeri amaçlarla kullanılması toplumda olumsuz izlenim yaratmış olduğundan bu yargıyı kırmak adına bu ismin kullanımından sonraki yıllarda kaçınılmıştır. Oysa teknik açıdan bakıldığında; dron, otomatik olarak gidebilen insansız hava ve deniz uçaklarını ifade ederken insansız hava aracı, insansız olarak uçabilen motoru olan ve kontrol edilebilen, kendisi bir silah olmayan uçakları ifade eder. Bu iki tanıma bakılırsa aralarında ufak farklar olsa da taşıdıkları anlam birbirine oldukça yakındır. İnsansız hava aracı sistemi ise

25 kilogramın altındaki insansız hava aracı ve faydalı yük, yer kontrol istasyonu ve yer veri birimi gibi bileşenlerinin birlikte ifade edilmesine olanak tanıyan terimdir.

Aracın sınıflandırması hususunda aracın boyutları, operasyon irtifası, maksimum uçuş süresi, faydalı yük taşıma kapasitesi, faydalı yük türü, uçuş yöntemi, komuta biçimi, kullanım amacı, kalkış ve iniş yöntemi gibi unsurların temel alınmaktadır. Aracın kullanıldığı ülke ve bölgeye bunun yanı sıra aracın sınıflandırıldığı kategorisine bağlı olarak tabii olduğu kural ve yükümlülükler de değişiklik göstermektedir. Bazı kurallar ise uluslararası bağlamda geçerlilik göstermektedir. Örneğin, okunan kaynaklardan edinilen bilgiler dahilinde, resmi gün doğumu ve gün batımı arasında kalan gündüz süresi dışında uçuş yapmak yasaktır. Aracın, pilotunun görüş mesafesinin dışında kullanılması, araçla doğrudan ilgisi bulunmayan kimseler için kişinin belirli bir yükseklik ve yatayda belirli bir mesafeden yakınında aracın uçurulması yasaktır. Havadaki azami hız sınırı ve aracın yerden azami yüksekliği bölgesel olarak değişkenlik gösterse de yasalarla limitlenmiştir.

Proje aracı, ağırlığı bakımından mikro hava aracı kategorisinde görülmektedir. Faydalı yükü ile birlikte toplam ağırlığı yaklaşık 1.350 gr olan aracı sınıf 1 kategorisinde görmek, yerinde olacaktır. Aracın boyutu değiştikçe avantajlar ve dezavantajlar da değişmekte, çeşitlenmektedir. Örneğin; küçük araçların, büyük araçlarla kıyaslandığında daha düşük pil kapasitesiyle, uzun uçuşlar için uygun olmasa da manevra kabiliyeti ve hızlanma süresinin daha kısa olmasıyla daha atletik oldukları düşünülebilir. Kanat aralığı uzadıkça motorların birbiri ile etkileşiminin azalması sonucunda denge kurabilme yetisi artan araçların, daha az türbülansa girmesi ve daha dengeli bir uçuşun söz konusu olması da büyük aracın avantajları arasında düşünülebilir.

İnsansız hava araçlarında sınıflandırma kriterleri (Çizelge 1.1) değerlendirilirken, belli markaların ürettiği fabrikasyon araçların ve milli savunma teşkilatı veya kurumsal savunma teknolojileri geliştiren şirketlerin ürettiği, saygın çevrelerce kabul görmüş tasarımların örnek verildiğine dikkat etmek ve proje aracının hangi kategoriye ait olduğuna karar verirken kesin sonuçlara varmanın mümkün olmayacağını göz ardı etmemek gerekir.

Çizelge 1.1 İnsansız Hava Araçlarının Sınıflandırılması (Akyürek)

Sınıf	Kategori	Operasyon İrtifası (feet)	Menzil Yarıçapı (km)	Havada Kalma Süresi (saat)	Örnek Sistemler
Sınıf 1 (<150 kg)	Mikro <2 kg	AGL* + 200	5	1	Black Widow, MicroStar, Microbat, FanCopter, QuattroCopter, M05quito, Homet, Mite, Arı
	Mini 2-20 kg	AGL + 3000	25	<2	ScanEagle, Skylark, DH3, Mikado, Aladin, Tracker, DragonEye, Raven, Pointer II, Carolo C40/P50, 5korpio, R-Max and R-50, RoboCopter, YH- 3005L, Bayraktar, Efe, Gözcü
	Küçük >20 kg	AGL + 5000	50	3 - 6	Hermes 90, Scorpi 6/30, Luna, SilverFox, EyeView, Firebird, R-Max Agri/ Photo, Homet, Raven, phantom, GoldenEye 100, Flyrt, Neptune
Sınıf 2 (150-600kg)	Taktik	AGL + 10000	200	6 - 10	Sperwer, İview 250, Watchkeeper, Hunter B, Mücke, Aerostar, Sniper, Falco, Armor X7, Smart UAV, UCAR, Eagle Eye+, Alice, Extender, Shadow 200/400 , Taktik (ODTÜ), Çaldıran, Karayel
Sınıf 3 (>600kg)	Operatif (MALE)	AGL + 45000	Sınırsız	24 - 48	Reaper, Hermes 900, Skyforce, Hermes 1500, Heron TP, MQ-1 Predator, Predator-IT, Eagle1/2, Darkstar, E-Hunter, Dominator, Anka
	Stratejik (HALE)	AGL + 65000	Sınırsız	24 - 48	Global Hawk, Raptor, Condor, Theseus, Hellos, Predator B/C, Libellule, EuroHawk, Mercator, SensorCraft, Global Observer, Pathfinder Plus
	Taarruz - Atak	AGL + 65000	Sınırsız	>48	Pegasus

Her ne kadar ağırlığı, menzili ve havada kalma süresi düşünüldüğünde aracı otomatik olarak bir sınıfa dahil saymış olsak dahi insansız hava araçlarını sınıflama konusunda Tablo 1’de değinilmeyen farklı parametre ve faktörler de mevcuttur. Ve aracın sadece boyutuna veya benzeri bir kaç özelliğine bakarak bir sınıfa ait kabul etmek yüzeysel bir çıkarımdan fazlası olmayacaktır. Aracın sınıflanmasının önemine gelince, araçların tabii oldukları hukuksal yaptırımlardan, aracın karşılaştırılması makul olan araçların seçimine

kadar pek çok konuda aracın sınıflanması gerekir. Aracın doğru sınıflanması, doğru değerlendirilmesinin ilk adımıdır.

1.2.3 Görsele dayalı yangın algılama sistemleri

Yangınların tespitinde görsel verileri baz alarak çalışan çeşitli algoritmalar mevcuttur. Bu algoritmalar temelde, aldıkları görüntüyü nesne tanıma, renk ayırt etme, köşe tanıma, katman algılama, kümeleme gibi algoritmalarla inceleyerek alev veya duman gibi yangın afetinin doğal belirtisi olabilecek görsel unsurların, aynı arazide yer alan diğer tehdit unsuru içermeyen nesnelerden ayırt edilmesi amacı gütmektedir. Güvenilir kaynaklarca onaylanmış literatür çalışmalarının taranması ve incelenmesi neticesinde bazı temel yaklaşımların bu alandaki çalışmalara ilham kaynağı olduğu gözlemlenmiştir.

İlk temel yaklaşımda, termal kameralar kullanılarak eşikleme (thresholding) metodu (Xeriansyah, 2007) ile yangının algılanmasıdır. Bu metodla çalışan algoritmalar, ısı yayan veya ısınmış nesneleri diğer nesnelerden ayırt edebilmektedir. Fakat alınan görüntüde, aynı ısıya sahip alanların aynı renkte gösterilmesi ile elde edilen bir desen dışında bir veri üretimi bulunmamaktadır. Bu durumda, ısı kaynağının çalışır durumdaki bir araba, vücut ısısı nedeniyle kameraya 'sıcak' görünen bir canlı veya yangın unsuru olup olmadığını anlayabilmek için bir eleme yöntemi kullanmak gerekecektir. Bu tür bir yaklaşım üzerine geliştirilen sistemlerde alınan görüntünün eşikleme değerlerine, sıcaklığın derecesine eşleştirilmiş değerler atanabilir. Örneğin 35 °C olan bir nesnenin beyazlık değeri düşükken, 80 °C ısıya sahip yangın unsurunun sıcaklığı ve buna bağlı görülebilen aydınlık değeri yüksek olacak şekilde programlanırsa, ısı yayan her cisim aynı kategoriye alınmaz, kendi içlerinde de kümeleme yoluna gidilir.

Bir diğer temel yaklaşım, gün ışığında gökyüzündeki dumanı algılayan bir algoritma (Wang vd. 2017) (Zhang vd. 2018) geliştirilmesi ve duman ile yangın ilişkisi üzerinden yangınların tespit edilmesini sağlamaktır. Geleneksel duman sensörleri, açık havada duman algılamada yetersiz kalmaktadır. Duman görselinin kendine has bir damga görüntüsü vardır. Öyle ki ayırt edilmesi için diğer görsellerle uyumlayacak olan bolca

niteliği barındırır. Bu nedenlerden dolayı, duman algılama projesinin görüntü işleme yazılımlarıyla temellendirilmesi akla yatkın bir yöntem olacaktır.

Gerçek hayatta farklı boyut ve renklerde, farklı zaman ve mekanlarda alınan duman kesitleri elle (manual) olarak bilgisayara tanımlanır. Yeterince eğitim verisi girildiğinde yazılım duman nesnesini ayırt etmek üzere bir model, bir analiz biçimi olmak üzere ayırt edici örnek (margin sample) geliştirmiş olur. Gelen görüntü verisi, önceden edinilmiş marjin örneği ile karşılaştırılarak tanımlanan niteliklere uygun nesnelere duman etiketi atanır ve yangın potansiyeli olduğu bilgisi istemciye gönderilir. Aynı yaklaşımın ateş veya alev algılayan versiyonlarına da literatür kaynaklarında (Çelik, 2010) (Chen vd. 2004) (Lei & Liu , 2013) (Merino vd. 2014) (Santana vd. 2012) (Seebamrungsat vd. 2014) (Wang & Zhou , 2012) (Wang vd. 2017) (Zhang vd. 2018) (Zhou vd. 2015) sıkça rastlanmaktadır. Optimum düzeyde görüntü girdileriyle eğitilen sistemler bir noktadan sonra gelen yeni veriyi sınıflayabilmektedir. Bu optimum değer öğrenmeye yetmeyecek kadar az olmamalı, ancak sistemi ezberlemeye itecek kadar da çok olmamalıdır. Bu kriteri sağlayacak sayıda ve nitelikte olması açısından veriler özenle seçilmelidir. Seçilen veriler ise yine dikkatlice sistemin isterlerini karşılayacak yönden kullanılarak yapay zeka uygulaması eğitilmelidir. Bu yaklaşımlara ek olarak üç fazlı görü temelli ateş belirleme algoritması (Chang, 2013) olarak da bilinen yangın nesnesinin içerdiği bölgeleri hayali (spectral) model, uzaysal (spatial) model ve geçici (temporal) model olarak görsel imaj dizilerine ayıştıran bir yaklaşım mevcuttur.

Bu üç fazlı modelleme algoritmasına göre, ilk faz olan hayali modelde, görsel girdinin yangın pikselleri, renk olasılık yoğunluğu cinsinden ifade edilir. İkinci faz olan uzaysal modelde, yangın nesnesinin alanında bulunan mekansal yapı ele geçirilir. Fourier katsayısı kullanılarak resimdeki yangın bölgesinin dış hatları ile uzayda kapladığı alanın şekli belirlenir. Üçüncü fazda hareket eden ve zaman parametresine bağlı olarak şekil değiştiren yangın nesnesinin anlık geçici biçimlerinin kendine has yönleri tutulur. Bu üç model ile yangının çeşitli bilgileri depolanır. Her ateş türü nesnenin kendine has bir imza görüntüsü mevcuttur. Renk, geometrik biçim ve devinim gibi bir yangın alanının tüm niteleyici özelliklerinin bilinmesi, ayırt etme açısından elzemdir.

Yangın bölgesinde bulunan piksellerin karakteristik özelliklerinin bir hayali modeli ve bölgenin içindeki mekansal varyasyon bilgisinin formüle edilmiş uzaysal modeli açısından yangın durumuna karşılık gelen bir kıyaslama-eşleştirme alanı yakalanabilir. Yangının şekli ve kapladığı alan genellikle devinerek, çevresel faktörlere bağlı olarak rastgele kararlaştırılmış, rastgele ihtimal dağılımı veya deseni oluşturur. Bu alan sonradan analiz edilerek istatistiksel anlamda genel bir ifadeyle bağdaştırılabilse de önceden kesin olarak öngörülmesi mümkün değildir. Yine de her yangın görece statik genel bir şekle sahiptir denebilir. Ve hızla değişen lokal şekli ve değişim sonucu kapsadığı değişken sınırlara sahiptir. Bu şekli betimleyen bir tür rastgele dağılımlı (stochastic) model oluşturularak zamana bağlı oluşan rastgele sınırlarının karakteristik bilgisi yakalanabilir. Bu bilgiden yararlanılarak da yangın tespiti sağlanabilir ve hatta zaman ve veri birikimi yardımıyla gelecekteki çalışmalarda, yangının hangi yönde ne kadar ilerleme eğiliminde olduğuna dair tahminlerde bulunulabilir.

Çelik'in yangın algılama uygulamaları için geliştirdiği görüntü işleme metodları yardımıyla hızlı ve verimli metodunu açıkladığı makalesi (Çelik, 2010) ise iki ana bölümden oluşan aşamalı bir yapıya sahiptir. Çelik, makalesinde yangının RGB renk uzayındaki özelliklerini tanımlamış, bir pikselin yangın görseline renk bakımından dahil olup olmayacağını iki grupta sunduğu kuralları kullanarak irdelemiştir. Uluslararası yayın indeksinde görsel verilerle yangın algılama alanında pek çok makaleden atıf almış ve geliştirilen pek çok uygulamanın temelini oluşturmuştur. Bu algoritma bir bütün olarak veya kısmi biçimde diğer basmakalıp yangın algılama algoritmaları ile paralel olarak kullanılabilir ve böylece yanlış alarmların da önüne büyük ölçüde geçilmiş olacaktır. Renk tanımlama modeli ile nesne sınıflandırma algoritmaları yangın piksellerini yalnızca renk bilgisine bakılarak doğru şekilde kümeleme görevinde umut vaat eden istatistiksel sonuçlar vermektedir. Ancak alevler her zaman kolayca görülecek biçimde olmayabilir.

Örneğin uzak mesafeden yapılan görsel taramalarda veya ateş ile kameranın arasında görsel gürültü, engel veya görüş alanını daraltacak başka bir faktör olursa, alev görselini bu gibi durumlarda aramak problemin çözümüne katkı sağlamayacaktır. Yine de insansız hava araçları ile mesafe ve engellerin sorun teşkil etmediği bir sistemde, hareketli görüntü alma kaynağı sayesinde, bu tür görüntü ayırt etme yöntemleri kullanılabilir.

Tez makalesinde geliştirilmesi tasarlanan metot iki biçimde çalışabilir. İlk olarak, belirlenen periyotta belirli sayıda resim çeken ve bu resimleri tarayarak anahtar nesneyi görselde arayan bir algoritma ile yangın tespit uygulaması geliştirilebilir. Bu metot hafıza korunması bakımından iyi olacaktır çünkü alınan görüntüler işlenerek tehdit unsuru içermediği tespit edildiğinde anlamsızlaşacağından silinebilir. Bu şekilde bir tür rekürsif işle – tara – kaldır – tekrar et prosedürü tanımlanabilir. Kullanılabilecek ikinci metot ise video akışı olarak akış içinde yangın bulgusuna rastlarsa alarm durumunu sisteme döndürür. Bu durumda video akışı zaten kaydedilmeyeceğinden, tek sorun dinamik verinin işlenmesi olacaktır. Bu iki metoddan biri seçilerek yangın taraması yapılır. Bunun dışında, otonom hava araçlarının önceden belirlenen rotada devriye gezmesi varsayılan hamle olarak belirlenir. Ancak bu durumda arazinin boyutuyla orantılı olarak alandaki her nokta uzun periyotlarda yalnızca bir kez ziyaret edilmiş olacaktır. Üstelik pil ömrü açısından bakıldığında, on beşer dakikada bir aracın batarya tazeleme üssüne dönmesi gerekecektir.

Uzaktan duman algılayan algoritmalarla kıyaslandığında, bu tez projesinde rotanın sabit belirlenmesi büyük bir handikapa yol açacaktır. Bunun üstesinden gelmek adına, insansız hava aracına harici bir kamera eklenerek ekstra bir görüş alanı kazanarak bu görüş alanında duman emaresi algılanması halinde araç kendine yeni bir rota çizerek yangın potansiyeli yüksek olan bölgelere ziyaret etme önceliği tanıyabilir. Bu yaklaşımların bir de sağlama algoritması ile pekiştirilmesi sonucunda, literatür analizinde bahsi geçen diğer çalışmaların bir adım önünde olacaktır. Görsele dayalı yangın algılama sistemlerinde çeşitli ayırt edici unsurlar seçilerek yapay öğrenme yoluyla duman ve alev görsellerinin doğru ve tam olarak saptanması hedeflenmiş ve bu hedef doğrultusunda çeşitli çalışmalar yürütülmüştür.

FiSmo (Cazzolato vd. 2017) ateş ve duman görsellerine ulaşmak için görseli parçalara ayırarak her bir parçayı yangın ve duman öğelerinin özellik vektörleriyle karşılaştırmış ve görselleri "yangın-var" (YV) ve "yangın-yok" (YY) kümelerine ayırmıştır. Sınıflandırma yapılırken her bir parçanın yerel renk pikselleri ve yerel doku niteliği dikkate alınmıştır. Bu kategorilere ayırma işlemi, temelde, görseli meydana getiren yapı taşlarının konumu ve birbirleriyle olan komşuluklarını ayırt edici unsur olarak kabul eder

ve bu sistematik ilerleme neticesinde bölgesel (local) sonuçlardan genel çıkarımlara varılır. Veri kümesinde görseller eğitim verisi olarak kullanılmadan önce, aynı resmin yalnızca bir kez kullanılmasına özen gösterilmiş, kullanılan görseller duruma göre etiketlenmiş ve "sadece duman" (SD), "sadece alev" (SA), "duman ve alev" (DA) ve "hiçbiri" olmak üzere alt kümelere bölünmüştür. Verilerin birden çok kez modelin eğitiminde veya testinde kullanılması, modelin başarısının yanlış değerlendirilmesine yol açabilir. Eğer birden çok defa kullanılan görselin sonucu olumlu ise modelin olumlu yöndeki, olumsuz ise modelin olumsuz yöndeki sonuçlarında asılsız bir artış eğilimi göstereceği varsayılmaktadır.

Duman görseli; su, sis, bulutlar ve ağaçlar gibi birçok farklı unsurla kolayca karıştırılabilir. Bu nedenle yangının tespit edilmesinde renk düzeni, ölçeklenebilir renk, renk yapısı, renk derecesi, köşe histogram, doku araştırma, doku spektrum gibi pek çok özellik çıkarıcı yöntem kullanılmıştır. Bunların yanı sıra sonuçlar içerik tabanlı bir gözden geçirme sürecinden geçmiştir. Video girdisini değerlendiren çoğu duman algılama algoritması dumanın devinimsel hareketini temel alır. Duman, renk bakımından gri tonlanmış pikseller içinde aranır. Gerçekte bulgu öğeleri aydınlatma, sıcaklık, yanan materyal gibi birçok faktörden etkilenmektedir.

Duman görselinin aranabilmesi için eğitim veri seti tanımlanırken gerçek hayattan alınmış görsellerin kullanılması yaygın olarak tercih edilmektedir. Ancak, gerçek hayattan alınan görsellerin boyutlandırmasındaki kısıtlar ve çeşitlilik açısından zengin olmaması nedeniyle sentetik duman görsellerinin üretilerek sistemin eğitilmesinde kullanılmasının uygun bulunduğu kaynaklara (Xu vd. 2017) da rastlanmıştır. Sentetik verilerin kullanılmasıyla, gerçek verilerin kullanılması arasındaki en temel fark duman görselinin bulunması açısından istatistiksel dağılımdır. Test verileri gerçek hayattan alınan görsellerden oluşacağı için eğitim verileri ile test verilerinin istatistiksel dağılımının birbirine uygun olmaması, hata oranını yükselterek problem teşkil edecektir. Etki alanı adaptasyonu (EAA) metoduyla (Xu vd. 2017) duman görselinin değişken özellik uzayı gerçek hayattan alınan görsellere göre adapte edilmektedir. Bu adaptasyon temelli yöntemde yürütülen ilk adım duman durumunun şartları göz önünde

bulundurularak yüksek deęişkenlik gösteren sentetik duman görsellerinin rastlantısal olarak üretilmesinin sağlanmasıdır.

Duman algılayan sistemlerde genel olarak görselin dokusundaki desenin algılanması, özellik çıkarıcı ve sınıflandırıcı tasarımlarıyla mümkün olmaktadır. Dumanın tipik karakteristik özellikleri; muhtemel renk ve hareket spektrumu, histogram dizisi, dinamik dokusunun çıkarılmasında Surfacelet Dönüşümü, geçici duman yörüngesi, devinim yönelimli model, yerel ekstrem bölge segmentasyonu gibi yöntemlerle çıkarılabilir.

Yangının erken fazlarında duman görseli dağınık bir transparan görünümde olduğu için görseli arka plandan bağımsız simüle etmek yerine arka planı duman katmanıyla perdelenmiş olacak şekilde kabul etmek daha gerçekçi sonuçlar almaya yarayacaktır. Aynı zamanda rüzgar etkisinin dumana vereceği şekil görselin görünümünü değiştireceğinden kapalı ortam ile açık ortamda çekilen fotoğraflar farklılık gösterecektir. Oluşturulacak sentetik verilerde de bu ayrım göz önünde bulundurulmalıdır. Bunun yanında, görselin hangi bakış açısından alındığı dumanın nasıl görüneceğini fazlasıyla etkilemektedir. Bu nedenle görseller değerlendirilirken bakış açısı tahminde bulunmak ve bu tahmini göz önünde bulundurarak görseli değerlendirmek daha gerçekçi sonuçlar elde etmeye yarayacaktır. Sentetik veriler üzerinde yürütülen bu çalışmadaki en ilginç unsurlardan biri, sentetik görsellerden gerçeğe hiç uymayan ve insan gözüyle bakıldığında gerçekçi görünmeyen sentetik verilerin de, gerçekçi görünenler kadar başarılı sonuçlar vermiş olmasıdır. Adaptasyona dayalı derin öğrenmede (Xu vd. 2017) farklı tasarım seçenekleri kullanılmış ve bunların sonuçları değerlendirilmiştir. Bu değerlendirmenin sonucunda, doğru bulunan sonuç oranının en yüksek kaçırılan veya yanlış tespit edilen verilerin en düşük olduğu veri seti, sentetik ve gerçek görsellerin karışımından oluşan hibrit küme olmuştur. Sentetik duman görseli, gerçeğine kıyasla dumansız örneklerle daha çok benzerlik gösterdiğinden daha yüksek kaçırma oranı vererek tespit edilemeyen çok sayıda örneği yanlış sınıflandırmaktadır. Sonuç olarak, bu tür bir veri kümesinde yürütülen iyi bir derin öğrenme süreci için, kullanılacak kaynak veri kümesinin içeriği oldukça etkilidir.

Video dizileri içinden dinamik yapıya bağlı yerel, bilimsel desenlerden yola çıkılarak dumanın algılanması (Lin vd. 2017) yangın algılama sistemlerinden biridir. Video içerisindeki düzensiz hareket alanlarının belirlenerek, destek vektör makinesi (SVM,Support Vector Machine) kullanılmasıyla dinamik doku özelliklerinin sınıflandırılması ve özellik vektörlerinin boyutlandırmasına dayalı bir yöntem kullanılmaktadır.

Birbirine komşu olan piksellerin ilişkisini göz önünde bulundurulma temeline dayanan bir yaklaşım (Lei & Sewchand , 2002) bulunmaktadır. Merkez pikselini bir eşik değeri kabul eden bir ikili (binary) desen çıkarılır. Bu desen filtresi, görsel üzerinde gezdirilerek aynı devinime sahip komşu pikseller sınıflandırılır. Bu makaleye göre titrek ışık ve hareket eden perdeler dumanla karıştırılabilecek öğelerdendir. Çünkü duman devinimine (Gao & Cheng , 2019) benzer bir akış ve hareket içerisindedirler. Makalede, bloklara bölünmüş görsellerdeki dinamik doku özelliklerinin ayrıştırılmasındansa, düzensiz hareket saptanan bölgeler üzerinden dinamik doku özelliklerin ayrıştırılmasının daha doğru sonuçlar verdiği ortaya konmuştur.

Orman yangınlarında duman tespiti için (ESA) evrişimli sinir ağları (Hohberg, 2015) da kullanılmaktadır. Bu çalışmada (Hohberg, 2015) da izleme kulelerinden alınan görseller üzerinde duman ögesi aranmaktadır. Kulelerin etrafındaki görülebilir mesafeyi; gündüz normal görüşlü kameralarla, gece ise infrared kameralarla tarayan bir sistem kurgulanmıştır. Çalışmanın makalesinde yapay sinir ağlarının çalışma prensibi, soyut olarak biyolojideki sinirsel iletme, matematiksel model olarak ise Turing Makinelerine benzetilmektedir. Yapay sinir ağındaki nöronlara rastlantısal gürültü eklenmesinin, veri kümesindeki genelleştirmeyi desteklediği ve dolayısıyla daha geniş test verileri için daha iyi sınıflandırma sonucu verebileceği savunulmaktadır.

Fshell algoritması (Hohberg, 2015) ile pikseller arası ilişki araştırılarak aynı ögenin parçası olan pikseller ilişkilendirilmiştir. Bu algoritma yürütülürken, her bir piksel referans pikselle karşılaştırılmış, eşiklendirmeye piksellerin birbirine bağlı olup olmadığına karar verilmiştir. Aralarındaki ilişkiye bağlı olarak fark yaratan bölgeler puanlandırılmıştır. İlişkilendirilmiş pikseller birleştirildiğinde eğim açısı, piksellerin

arasındaki uzaklık ve birbirleriyle olan ilişki açısından duman görselinin parçacıklarıyla eşleşen pikseller duman sınıfına dahil edilir. Aynı zamanda çalışmanın makalesinde gerçekleştirilen sistemde kullanılıyor olmasına rağmen, yangın algılama sistemlerinde gözlem kulelerinin kullanılmasının bir handikapından bahsedilmiştir. Yangın kaynağı, kulenin çok yakınındaysa duman, kameranın üzerinde kalan bir alanda oluşacağı için görüş çerçevesinin dışında kalacaktır.

Gerçek zamanlı orman yangını saptanmasında korelasyon tanımlayıcıları da kullanılabilir. Videodaki alanlar zaman-mekansal hareket alanlarına bölünür ve bölünen bloklar arasındaki korelasyon özellikleri çıkarılır. Bu makaleye (Habiboğlu vd. 2011) göre, duman karakteristiği dumanın dağınıklığı, görünür hacmi, maksimum yüksekliği, grilik seviyesi ve eğim açısidir. Ve bu karakteristik özellikler göz önünde bulundurulduğunda, duman görseline en yakın hareketset devinim bulutlarda bulunmaktadır. Bu nedenle, hareket algılanan bölgeler sınıflandırılmadan önce ayrıca hareket eden alanların hızının saptanması, hareket eden alanların renginin saptanması ve hareket eden alanlarda korelasyon bazlı bir sınıflandırma yapılması aşamalarından da geçirilir. Hareketli alanlardaki hızlı ölçmek için arka plan ayrıştırma yapılır ve arka plan yavaşça ve hızı artırılarak güncellenecektir, böylece hareket eden nesneler tespit edilebilecektir. Duman renk modelinde (Wang & Zhou , 2012) ise lüminansı çok yüksek fakat krominansı çok düşük olan bölgelere odaklanılır. Çünkü, çoğu duman görselinin ışık değeri fazla aydınlık ve doygunluğu renksiz denilecek kadar düşük görünür. Korelasyon metodunda ise bir destek vektör makinesi yardımıyla ikili maske oluşturularak piksel özellik vektörleri ile komşu pikseller arasında bir ilişki kurulur.

FiSmo (Cazzolato vd. 2017) çalışmasında sistem FlickerAPI üzerinden alınan yangın, kaza, alev, tutuşma, kamp ateşi, yanma, alev, kundakçılık, araba kazası gibi geniş bir yelpazede sonuçlar döndürecek anahtar kelimelerle ilişkili verilerin işlenip ayıklanmasıyla elde edilen bir veri kümesi ile eğitilmiştir. Oysa aynı çalışmada arkaplan öğelerinin ormanda ve şehirde değişeceğinden yangın senaryosunun tatbik edileceği mekandan alınan verilerle veya muadilleriyle eğitilen sistemlerin, test aşamasında daha doğru sonuçlar verebileceğine değinilmiştir. Bu durumda eğitim veri kümesi ile test veri kümesi arasındaki fark ne kadar az olursa, sistemin doğru ve tam çalışma oranı o

doğrultuda artacaktır. Bu çalışmanın (Cazzolato vd. 2017) insansız hava araçları ile görsele dayalı yangın algılama sisteminden farkı temelde, eğitim seti verilerinin orman yangını görselleriyle kısıtlanmamış olması dolayısıyla daha genel bir test kümesine göre tasarlanmış olmasıdır.

1.3 Problem Formülasyonu

Yangın, erken algılanması ve erken müdahale edilmesi halinde hasar miktarı ciddi ölçüde azaltılabilen bir doğal afettir. Yangınla savaşta, itfaiye kuvvetlerinin üstün çabalarına rağmen; trafik, geç gelen ihbarlar, yangın alanının arazözlerle müdahale açısından elverişli konumda olmaması gibi sebeplerle bazen yangına zamanında müdahale edilememektedir. Bu şekilde can ve mal kayıplarına neden olan elim gerçek, yangınla savaş sistemlerini gelişime ve iyileşmeye teşvik etmiştir. Konu orman yangınları olduğunda ise trafik veya yangının bulunduğu konum gibi metropolitan yaşamın ürettiği engeller yerine, zaman kısıtı aşılması gereken en önemli engeldir. Çünkü orman yangınları, en hızlı yayılan ve en geç fark edilen yangın tipidir.

Üzerinde bulunduğumuz coğrafyada sıkça meydana gelen orman yangınlarının geç tespit edilmesi ve bu yangınlara geç müdahalelerde bulunulması sebepleriyle, ülkemizdeki yeşil alanlar gün geçtikçe daralmaktadır. Orman yangınlarının yoğunlukla meydana geldiği illerde ve yerel yönetim kurumlarının yangınla savaş ekipleri tarafından su tankeri ve arazöz araçlarının yanı sıra, helikopterlerle su taşınarak hava yoluyla da yangınlara müdahale edildiği ve bu yolla kara araçlarından daha hızlı sonuçlar elde edildiği bilinmektedir. Helikopter gövdelerinin altına yerleştirilen su hazneleri ile yangın bölgesine ulaşarak, suyun havadan boşaltılması yangını ivedilikle dindiren bir yöntemdir. Bunun haricinde günümüzde yangınla savaş birimleri tarafından aktif olarak kullanılan bilgisayarlı yangın tespit sistemleri var olsa da yangına kısa sürede ve etkili biçimde müdahale etmek sıklıkla mümkün olamamaktadır. Ormanlık arazilerin fiziksel yapısı ve orman yangınlarının yayılma hızına kıyasla karasal müdahale araçlarının hızının yetersiz kalması göz önünde bulundurulduğunda, orman yangınlarına müdahalede hava araçlarının kullanım alanlarının genişletilmesi, yangını durdurma veya yayılmasını engelleme amaçlarının yanı sıra yangınların erken tespiti ve gerekli merkezi birimlere

yangın ihbarında bulunulması için de hava araçlarının kullanılması, yangınlara daha etkili biçimde müdahalede bulunulmasına imkan sağlayacaktır. Bilgisayarlı görü ve yapay zeka sistemleri ile yangın ihbarlarının hayata geçirilmeden önce teyit edilmesi, yanlış ihbarların da önüne geçerek kazanç sağlayacaktır.

Problemi modellemek için öncelikle problemin etraflıca algılanması ve eğer problem bileşik yapıdaysa, problem bütününe alt problemlere bölünerek daha kolay idare edilmesini sağlamak gerekir. Problem, insansız hava araçları ile dinamik görsel verinin işlenerek ön tanımlı, özgül nesnenin ayırt edilmesi ve algılanan nesnenin ilgili bazı anlık bilgilerinin ölçülerek merkezi birimlere iletilmesi olmak üzere iki parçaya bölünebilir. Bu iki alt probleme ek olarak zaman kısıtının problemdeki ana limit olduğu çeşitli kısıtlardan oluşan evrensel küme için optimum koşulların sağlanması amacı güdülmektedir.

İlk alt problem incelendiğinde, farklı boyut ve renklerdeki nesnelerin bulunduğu geniş bir arazinin belirli yükseklikten alınan görüntü çerçevesinin içinden seçilen özellikleri karşılayan nesnenin seçilmesidir. Yangın algılama olarak adlandırabileceğimiz bu alt problemin çözümü için nesne tanıma, nesne algılama, görsel veride kenar tanıma ve benzeri konulardaki güncel çalışmalar literatür taraması başlığı altında irdelenecek, bu çalışmalarda kullanılan çözüm yolları orman yangınlarıyla savaş temalı, asıl probleme uyarlanarak ve gerekli yenilikler ve iyileştirmelerle geliştirilerek kullanılacaktır. İnsansız hava aracına entegre edilmiş mikrodenetleyici (mini bilgisayar), aldığı görüntü verisini görseli tarayarak, görüntünün tehdit unsuru içerip içermediğini kontrol eder. Bu adımda eğer tehdit unsuru tespit edilmemişse, araç rutin devriyesini sürdürerek yoluna devam eder. Tehdit unsuru tespit edilir ve görüntü işleme yazılımı ile yangın ifade eden duman, alev, ateş gibi nesneleri ayırt edilirse, yanlış alarmların önüne geçmek adına insansız hava aracı yeniden konuşlandırılarak, yangın potansiyeli olan konuma yaklaşarak askıda kalma (hower) durumuna geçer. Bu haldeyken alanın yeniden görüntüsü alınır ve bu görüntü üzerinden bu kez kenar belirleme filtreleri aracılığıyla yangın unsuruna renk niteliği bakımından uyan nesnenin kenar modeli çıkarılmış olur.

Sistemin, dumanı tanımak üzere eğitildiği aşamada bir çeşit özellik haritası çıkarılacaktır. Bu harita temel alınarak, işlenecek güncel verinin herhangi bir tehdit unsuru kümesine

dahil olup olmadığı kontrol edilebilir. Bu işlemde de pozitif sonuçla çıkan görsel alan için bu kez termal kamera görüntüsünden, ısı yayan bir nesneye benzeyip benzemediği kontrol edilebilir. Bu üç aşamayı geçen unsur, yangın ifade ediyor kabul edilerek, kablosuz iletişim yoluyla alarm sinyali ve yangının konum bilgisi, rüzgarın yönü ve şiddeti, tahmini yayılma süresi ve alanı gibi veriler oluşturularak gerekli birimlere iletilir. Tehdit unsuru içermeyen görsel veriler derhal bellekten silinmeli, böylece yer tasarrufu sağlanmalıdır.

Problemin ikinci ana basamağı ise tehdit unsuru algılayan cihazların merkezi kontrol birimleri ile iletişime geçerek, yangının konumu, şiddeti, rüzgarın yönü ve hızı gibi yangının muhtemel yayılma hızını etkileyebilecek faktörler en acil biçimde yetkili müdahale birimlerine yönlendirilmesidir.

Bu görevin sağlanması yangınla savaş için gelecek ekibin, ne ile karşı karşıya olduğunun bilinci ve hazırlığıyla görev yerine gelmesini, böylece daha etkili bir müdahale operasyonunun gerçekleştirilmesini sağlayacaktır. Yangının bilgileri ve söndürülmesine kadar geçen süre bakımından en uygun olan müdahale yöntemlerinin merkezi bir veritabanına kaydedilmesiyle, gelecekte bu verilerin analizi ve etkin müdahale biçimlerinin sistematik olarak eşleştirildiği bir otomasyon sistemi de tasarlanabilir.

Alarm durumuna geçen sistemin alarm sinyalinin yanı sıra yollayacağı veriler için GPS ile konum belirlenmesi, mikrodenetleyiciye entegre edilecek anemometre ile rüzgarın hızının ve yönünün tespit edilmesi, görüntü işleme metodları ile yangının ne kadar geniş bir alanda etkili olduğunun belirlenmesi işlemlerinin mümkün olan en kısa sürede gerçekleştirilerek, elde edilen bilgilerin en hızlı ve fiziksel koşullara en uygun olan veri iletişim yoluyla gönderilmesi bu problem aşamasının temelidir.

Alt problemler arasında daha az önem taşıyan problemlerden biri de dronun devriye programının ve güzergahının tasarlanması, ormanlık alanların hava sahasında periyodik aralıklarla devriye gezen döner kanatlı insansız hava araçlarının, bölgeyi görüntü işleme teknikleri kullanarak taramasıdır. Bu devriye uçuşlarının sıklığı, optimum düzeyde ayarlanmalıdır. Çok sık bir periyotta görev alan dronların bataryaları çok sık tükenecek,

cihazlar hava koşullarından daha çok etkilenecektir ve muhtemelen toplam keşif uçuşu sayısı ile yangının rapor edildiği uçuş sayısı oranı anormal bir tutarsızlık gösterecektir.

Öyle ki uçuşların sayısı, yangın ihbarı sayısına oranla kabul edilebilir maliyette olmalıdır. Çok seyrek tayin edilen uçuş periyodu ise yangına zamanında müdahale etme avantajını kaybetmeye yol açabilir. Bu sebeple maksimum verim için, insansız hava araçlarının keşif uçuşlarının periyodu ve havada kalma süresi optimum bir sayısal değerde tutulmalıdır. Keşif uçuşları esnasında dronlar, yine belirli bir süre aralığıyla görsel veriler almalı ve bu verileri minimum sürede işleyerek tehdit oluşturabilecek bir alev, ateş, yangın veya duman ifadesinin görselde yer alıp almadığını sorgulamalıdır.

1.4 Tezin Hedefi

Tezin konu edindiği projenin hedefi, insansız hava araçları ile sağlanan görü ve hareket yetisi kapsamında, orman yangınlarında alınan sonuçlardaki hata oranının en aza indirgenmesidir. Bu amaç doğrultusunda, insansız hava aracı üzerinde sisteme entegre çalışan bir mikrodenetleyici, önce derin öğrenme ile duman görseli için eğitilerek programlanacak ve araca görüntü anlamlandırma becerisi kazandırılacaktır. Sonra gerçek zamanlı uçuş testleri ve modelin tahmin başarısının analizi sonucunda sistem iyileştirilerek geliştirilecektir.

Projede yapay öğrenmede ve duman ayırt etme görevi Raspberry Pi mikrodenetleyicisi üzerinde yürütülen Tensorflow kütüphanesi ile geliştirilmiş Python dilinde yazılan yapay zeka uygulaması ile gerçekleştirilmiştir. Model, önce masaüstü bilgisayarında eğitilmiş, sonra Raspberry Pi modülü üzerine eğitilmiş modelin gereken kısımları eklenerek, cihaza duman tanıma özelliği kazandırılmıştır.

Raspberry Pi, bilgisayar programlama projelerini robotik ile birleştirmek, kendin yap tarzı projelerle, gündelik hayatta karşılaşılan sorunlara elektronik ve yazılımsal çözümler üretmek isteyen kişiler için mükemmel bir mini bilgisayardır. Projede kullanılan bu cihaz ve nasıl kullanılacağı hakkında, tez çalışmasında yeterince bilgi mevcuttur. Bu bakımdan,

tezin amaçlarından biri de ilgili kişilerin Raspberry Pi mini bilgisayarının kullanımı ile ilgili bilgi edinebileceği bir kaynak teşkil etmesidir.

Her ne kadar araştırma çalışmasının temel hedefi orman yangınlarında meydana gelen hasarın en aza indirilmesi olsa da bunun yanı sıra gelişen teknolojilerden insansız hava araçları ile yazılım programlarının entegre çalıştığı sistemlerle farklı problemlerin de çözülebileceğine dikkat çekmek ve bu tür projelere teşvik etmek de tez projesinin hedefleri arasındadır.

1.5 Tezin Organizasyonu

Çalışma yürütülmeden önce, proje konusunun faydalı ve gerçekçi bir ruha sahip olması kriterini sağlaması beklenmiş ve bu doğrultuda bir tercih yapılmıştır. İnsansız hava aracı teknolojilerinin günden güne artan cazibesi beraberinde manuel ve internet ortamından erişilebilecek bilgi kaynaklarının da artmasına yol açmıştır. Aynı şekilde projede kullanılan Raspberry Pi modülünün de gömülü yazılım ve robotik projelerinde neredeyse bir mini bilgisayar denebilecek kapasite ve güçte çalışabilir durumda olması nedeniyle literatür ve metodoloji analizlerinin donanımsal kısmında epey vakit harcanmış, çok geniş bir bilgi kaynağı içinden faydalı ve ilişkili olan parçalar değerlendirilerek bu çalışmada gerekli kısımlarına yer verilmiştir. Fakat projenin gerçekleşmesi, insansız hava aracının yürür hale getirilmesi, mikrodenetleyiciye işletim sisteminin ve gerekli ortam platformlarının yüklenmesi, yazılımsal olarak görevlerin programlanması gibi aşamaların tümünde bu kaynaklardan edinilen bilgiler kullanılmıştır.

Tez çalışmasının hatlarına bakıldığında, bilgilendirme, özet ve giriş kısımları ile problemin formülasyonu bölümlerine göz atan okuyucu, proje hakkında genel bilgiye sahip olacaktır. Arkaplan ve literatür kısmında proje ile ilgisi bulunan bilimsel çalışmaların ve yaklaşımların önemli kısımları hakkında fikir edinilebilir.

Ön hazırlık bölümünde yapay zeka ve görüntü işleme yazılımının çalışacağı test ve eğitim verilerinin edinilmesi sırasında göz önünde bulundurulmuş şartlar ve değişikliklerin

sonulara olacak muhtemel etkisinden bahsedilmektedir. İnsansız hava araçlarıyla yangın algılama bölümüne gelindiğinde ise, projede kullanılan metotlara ve yazılımsal detaylara rastlanacaktır. Yürütölen testlerin sonuları ise sonu ve gelecek alışmalar bölümünde yer almaktadır.

2. KURAMSAL TEMELLER

Ön işlemlerle uygun hale getirilen verilerin kullanılması modelin doğru sınıflandırma oranını ve doğru sınıflandırdığı nesnelerin tahmin yüzdesini arttıracğından, kullanılacak öğeler ön işlemlere tabi tutulmuştur.

2.1 Veri Kümelerinin Oluşturulması

Projede devriye gezen insansız hava aracının manevra kabiliyeti ve mobil oluşu sayesinde, aynı bölge pek çok açıdan taranacağından sistemin eğitilmesinde kullanılan verilerin de, görsele bakış açısı ve görseldeki dumanın boyutları bakımından çeşitlilik göstermesi şartı aranmıştır. Literatür çalışmalarından edinilen bilgiler dikkate alınarak, sentetik ve gerçek hayattan alınmış verilerden meydana gelen hibrit bir eğitim veri seti kullanılmasının, doğruluk oranını yükselteceği varsayılarak modelin eğitilmesi ve test edilmesinde kullanılacak veriler karma bir veri havuzundan alınmıştır. Tensorflow kütüphanesi kullanılarak nesne tanımak üzere eğitilecek modele aktarılabilecek fotoğraflar, kullanılmadan önce bazı aşamalardan geçmelidir. Böylece hem eğitim süreci kısaltılabilir hem de aranan nesne dışındaki nesnelerin aranan nesnenin sınıfında gösterilme oranı düşerken, aranan nesnenin sınıfı ile ilgili modelin doğru tahminde bulunma oranı artacaktır.

Verilerin modelin eğitiminde kullanılmadan önce geçecekleri aşamalar; verilerin normalizasyonu, veri kümesinin segmentasyonu, verilerin etiketlenmesi ve xml uzantılı etiket dosyalarının da eğitim dizinine dahil edilmesi olarak ifade edilebilir. Her bir ön aşamayı kendi içinde detaylandırmak gerekirse; verilerin normalizasyonu aşamasında veri kümesindeki resimlerin içerdiği piksellerin histogram değerlerinin belirli bir renk aralığına getirilir ve resimler yeniden boyutlandırılır; veri kümesi segmentasyonu aşamasında verilerin tamamını yansıtacak şekilde homojen bir %10'luk kısmı test verisi olarak, geri kalan %90'ı eğitim verisi olarak ayrılır; verilerin etiketlenmesi lxml kütüphanesi ile aranan nesnenin resimdeki konumuyla birlikte işaretlenmesi ve etiketlenmesi işlemlerini içerir; bu xml uzantılı etiket de eğitim dosyasına eklenerek modelin eğitim sürecine katılır.

2.2 Kamera Ve Görüş Açısı Değişkenlerinin Değerlendirilmesi

İnsansız hava aracıyla kurulacak sistem çalıştığında karşılaşılabilecek görsellere benzer görsellerden meydana gelen test verileriyle yapılacak değerlendirme gerçeğe en yakın sonuçların elde edilmesi bakımından önemli rol oynamaktadır. Perspektif etkisi göz

önüne alındığında görüntünün alındığı bakış açısı ne kadar uzaklaşırsa görselin kenar açıları ve şeklinde o kadar bozulmalar ve değişimler meydana gelecektir. İnsansız hava aracının hareketi sırasında hiçbir ağaç boyundan daha alçağa inmeyeceği ve hatta daha geniş alanı gözlemleyebilmesi açısından, aracın devriye gezeceği standart yüksekliğin 5-on metre aralığında tercih edildiği düşünülürse aracın duman verisine bakış yönü doğrudan karşılıklı olabilir veya duman görseli aracın bakış ufkunun biraz altında veya üstünde kalabilir. Hangi açı oluşturulursa oluşturulsun, sürekli hareket halinde olan bir araç aynı cisme bakarken bile farklı görseller görecektir. Cisim on metre uzaktayken, aynı cismin beş metre uzaktayken görüldüğüne kıyasla daha küçük ve daha detaysız görünecektir. Test ve eğitim verilerinin örtüşmesinin önemi dikkate alınacak olursa, sistemin eğitildiği veri kümelerinin de farklı boyutlarda ve farklı açılardan çekilmiş duman görsellerini içermesi önemsenmiştir.

Derin öğrenme modeli eğitilirken, verilen küme içerisindeki işlenmekte olan fotoğrafta aranan nesneyi içeren bölüm, modelin o ana dek çıkardığı özellik haritasıyla örtüşene dek analiz ediliyor ve sonuç olarak ortak nitelik olduğu yüksek ihtimalle kabul edilebilecek olan yeni parametrelerin özellik haritasına eklenmesi ile özellik haritası güncelleniyor ve haritada var olduğu halde işlenen fotoğrafta rastlanmayan niteliklerin kesinlik payı ve modelin karar mekanizmasına etkisi düşürülüyor.

Bu çalışma prensibi düşünüldüğünde, farklı bakış açılarından alınan verilerin kullanımı sırasında dikkat edilmesi gereken nokta, fotoğraflar özellik haritasındaki ortak nitelik genellemesini açacak derecede farklı görünmemesi gerektiğidir. Aksi takdirde ayırt edici kritik bazı nitelikler ölçme kriterleri dışında bırakılabilir veya eğitim süreci olması gerekenden dramatik ölçüde daha uzun sürebilir. Özetle bakış açısı insansız hava aracı görüşüne yakın noktalardan çekilen ve birbirinden aşırı farklı görünmeyen fotoğraflardan oluşan eğitim veri setinin kullanımı ideal olacaktır.

3. MATERYAL VE YÖNTEM

İnsansız hava araçlarıyla görsele dayalı erken yangın algılama sisteminde yangın görselinin işlenerek orman yangınının tespiti hedefi doğrultusunda kullanılan donanımsal

ve yazılımsal araçlar ve teknikler bu bölümde incelenecektir. Sistemin en temel bileşeni, aracın güç kaynağından beslenen mikrodnetleyicidir. Sistemin yangın durumunu algılayabilmesi için görsel veri kümeleri kullanılarak eğitilecek olan program bu bileşen üzerinde çalıştırılacaktır. Bir bakıma projenin beyni olarak rol alan bu parça için projede Raspberry Pi mikrodnetleyicinin kullanımı uygun bulunmuştur. Cihaza, kendine has geliştirilen ve pek çok programı sorunsuz ve hızla çalıştırabilen Raspbian işletim sistemi yüklenmiştir.

Debian tabanlı bir işletim sistemi olan Raspbian; OpenCV, Tensorflow vb. görüntü işleme ve yapay öğrenme kütüphanelerinin kullanımına uygundur ve mikrodnetleyiciye işletim sisteminin kurulumunun ardından terminal komut satırı üzerinden standart Linux komutları ile programların yüklenmesi ve çalışır hale getirilmesi mümkün olmuştur. Yapay öğrenme yetisinin araca kazandırılması noktasında, Python 3.6 dili kullanılmış ve pip üzerinden pillow, lxml, jupyter, Matplotlib, OpenCV ve Tensorflow kütüphaneleri kullanılmak üzere tanımlanmıştır.

Duman görselinin arkaplan öğelerinden ayırt edilebilmesi için kullanılan modelde tanımlı, yürütülecek adımlar arasında arkaplan ayırıştırma, renk ve kenar modelleme, veri normalizasyonu gibi yöntemler bulunmaktadır.

Projede kullanılan kütüphanelerde gömülü(built-in) bulunan metotlar, fonksiyonlar ve tanımlı değerler yardımıyla, modelin eğitim aşamasından sonra çağırılması ve kullanılması sırasında yapılması gereken adımlar masrafsız ve işlemciyi yormayacak şekilde ilerler.

Materyal ve yöntem bölümünün alt başlıklarında, uygulamanın kurma ve başlatma adımları, modelin tanımlanması ve eğitilmesi, yeni alınmış bir Raspberry üzerine modelin kurulup çalışır hale getirilmesi süreçlerinin tümüne yer verilmektedir.

3.1 Tensorflow Kütüphanesi

2015 yılında Google tarafından geliştirilen, açık kaynaklı Tensorflow kütüphanesi sayesinde, derin öğrenme destekli yapay zeka projeleri geliştirmek mümkündür. Bu kütüphane, kullanılan bilgisayarın GPU veya CPU bileşenleri üzerinden kullanılabilir. Tensorflow kütüphanesi Python, C++, C#, Java, Javascript gibi pek çok yazılım dilini de desteklemektedir. Tez konusu projede Python dilinin kullanılması uygun bulunmuştur.

Tensorflow kütüphanesi, mobil veya web tabanlı uygulamalarda veya IoT cihazlarda geliştirilen projeler için kullanılmaktadır. Daha önce Raspberry üzerinden Tensorflow ve OpenCV kütüphaneleri kullanılarak geliştirilmiş pek çok uygulama mevcuttur ve incelenmiştir. Örneğin; bir yazılımcı, tuvaleti geldiğinde, evin dış kapısının önünde dikilen kedisinin ihtiyacını anlayan ve dışarı saldıgı kedisi eve döndüğünde kapıda içeri alınmayı beklerken kendisine cep telefonuna kısa mesaj atmak yoluyla durumu bildiren bir Raspberry Pi projesi geliştirmiştir. Bu ve benzeri, mimik tanıyan ve mimiğe göre emoji oluşturan (Joseph & Geetha , 2019) kafa hareketleri ile yönlendirilebilen video oyunları gibi yapay zeka ile farklı bir boyut kazandırılan uygulamalar geliştirilmiştir. Bu uygulamalar incelendiğinde Raspberry Pi'nin, OpenCV ve Tensorflow kütüphaneleri ile desteklenerek, insansız hava aracı ile entegre çalışarak, yangın tanımada kullanılması, makul ve gerçekleşmesi mümkün bir proje olarak görülmüştür.

3.1.1 Tensorflow çalışma prensibi

Tensorflow, nesne tanıma uygulamalarında ayırt edilecek nesne için sistemin eğitilmesinde kullanılan bir kütüphanedir. Tensorflow modelinde, nesnenin ayırt edici nitelikleri tensör adı verilen veri tipi kullanılarak çıkarılmaktadır. Tensör, matematiksel ve fiziksel ölçümlerde çok boyutlu değişkenlerin ölçülmesinde kullanılan bir niceliktir ve derin öğrenme algoritmalarının eğitim sürecinde, eğitim veri kümesindeki fotoğraflar sisteme yüklenir ve işlenirken, veri akışı içindeki ayırt edici niteliklerin kaydedilmesine yarar. Skalar ve vektör nitelikleri tanımlı bakımından kavrama kabiliyetini zorlamayan tanımlar olsa da bu iki terimin birer üyesi olduğu tensör genel tanımlı, anlaşılması

bakımından daha çetrefillidir. Skalar, herhangi bir fiziksel ölçümün değerini ifade eden niceliktir.

Örneğin; 10 cm, 30 Celcius, 5 kg gibi tek boyutlu ve yönsüz bir büyüklüğü birimiyle birlikte ifade ederken kullandığımız değerler birer skalar büyüklük nitelemektedir. Vektör, standart kartezyen koordinat sisteminde bir değişkenin x ve y düzlemleri üzerindeki izdüşüm değerlerini birlikte niteleyen; ivme, kuvvet, yönü belirtilmiş hız gibi hem yön hem de büyüklük bildiren bir tür niceliktir. Skalar, sıfıncı dereceden, vektör birinci dereceden tensördür. Bir kübün her bir yüzeyine etki eden standart koordinat sisteminde x , y ve z düzlemleri yönündeki kuvvetleri tek nicelikte ifade eden $n \times n$ boyutlu bir matris, ikinci dereceden bir tensörü ifade etmektedir. Bir tensörün rankı, o tensörün boyutudur.

Tensör, iç içe geçmiş vektörlerden meydana gelen ve vektörler arası tanımlı operasyonlarla, tensörü oluşturan birimlerden birinde meydana gelen değişimin, diğer tüm birimlere olan etkisini ölçerek sistemdeki vektörlerin birbiri ile olan doğrusal ilişkisini ve bağlantısını tanımlamaya yarayan niceliktir. Uzayda sabit duran bir nesnenin değerlendirildiği koordinat sisteminde orijin eksenleri değiştirilirse, yani nesnenin içinde bulunduğu uzay, ölçeklenir veya eğimlenirse, bu nesnenin görünümü değişecektir, nesnenin değişmiş halinin, yeni orijin eksenleri üzerinde bıraktığı izdüşüm ile eski sistemdeki aynı cinsten izdüşüm değerleri arasındaki değişim faktörü metrik tensör olarak ifade edilmektedir.

Ait olduğu koordinat sistemi değiştirilerek farklı bir düzleme aktarılan nesneler, yeni düzlemdeki izdüşümü ile orjinal boyutları arasında metrik tensör kadar bir kalibrasyon farkına sahiptir.

Metrik tensör kavramı, içinde bulunduğumuz uzayın geometrisinin, öklid uzayından ne kadar farklı olduğunu ve ne kadar kalibre olduğunu söyleyen niceliktir. Daha genel bakılacak olursa, farklı uzayların yapıları arasındaki kalibrasyon farkını tek bir ifadede özetleyen niteliktir. Tensorflow kitaplığı açısından değerlendirilecek olursa tensör, çok boyutlu bir dizi içinde tutulan ilkel (integer,float) verilerden oluşan çok boyutlu veri

yapısıdır. Akış içindeki resimlerin aynı nesneyi içerdiği belirtilen belirli bölgeleri karşılaştırıldığında saptanan farkın ve benzerliğin matematiksel olarak tutulmasına yarar. Tensorflow diyagramında, modelin başarısının tahmini ve gerçek değerinin farkını ölçen fonksiyon (total loss function) bire yaklaşıp kadar süren iyileştirmeler ve eğitimle, test görsellerinin en doğru sınıflanmasında etkili faktörlerinin tanımlanması ve modeldeki nesneler için özellik haritasının çıkarılması amaçlanır.

3.1.2 Tensorflow ile nesne tanıma

Nesne tanıma algoritması çalışırken, ayırt edilmesi beklenen nesne, modelde tanımlanırken, düğümlerden (node) meydana gelen ve bir akış diyagramı ile gösterilebilen, bir dizi hesaplama işlemi yürütülür. Genellikle her düğüm bir tensör alır, hesaplamasını yapar ve bir tensör çıkarır. Öğrenme modellerinde aynı girdilerle, farklı ve iyileştirilmiş çıktılar almak hedeflenir. Bunun sağlanması için de Tensorflow değişkenleri, operasyonlar, yer tutucular ve sabitler kullanılarak akış içindeki tensörler güncellenir ve iterasyon sürdürülür. Makine öğrenmesinde iyileştirme güncellemeleri elle yapılamaz, kayıp fonksiyonu (loss function) adı verilen, modelin tahmini başarı değeri ile test verisini sınıflandırmadaki başarısı arasındaki farkı ölçmede kullanılan fonksiyonun anlık değerini minimize edecek (optimizer) bir eğitim (API) uygulaması vardır. Uygulamada veri kümesindeki resimlerden, bir nesne için bir özellik modeli (feature map) oluşturulur. Piksellerin birbiri ile olan ilişkisi tutulur ve benzer bir ilişkiye diğer resimlerdeki nesneyi içeren bölgede rastlandıkça o nesne ile korelasyon değeri beslenir.

Belirli iterasyon birimi olan yığın(batch) içindeki eğitim resimleri, sonunda test verisi ile kıyaslanır ve sınıflama ile gerçekte ait olduğu sınıf arasındaki farka göre model optimize edilerek güncellenir.

3.2 Raspberry Pi 3 Model B+

Raspberry Pi, 2012 yılında okullarda öğrencilere bilgisayar biliminin daha iyi öğretilmesi ve öğrenci bütçesiyle dahi çok çeşitli projelerin geliştirilebildiği bir SBC (Single Board Computer) Tek Kartta Bilgisayar teknolojisi ürünüdür.

Bir masaüstü bilgisayara oldukça yakın bir donanımsal yapısı ve çalışma prensibi olsa da Raspberry Pi, üretim amacı gereği düşük bütçeli, hafif, mobil ve az enerji tüketen bir yapıya sahiptir. Standart masaüstü bilgisayarların işlemcilerinden farklı olarak işlemcisi, 64-bit destekli dört çekirdekli Quad-Core 1.4GHz Broadcom BCM-2837B0, Cortex-A53/AMRv8 işlemci kullanır. Bu işlemci, hem Debian tabanlı işletim sistemleri ile hem de özel olarak geliştirilmiş Windows 10 IoT Core isimli işletim sistemi ile çalıştırılabilmektedir. Linux tabanlı bir işletim sistemi ile çalıştırıldığında, cihazı terminal istemcisi üzerinden Linux terminal komutlarıyla yönlendirmek gerekirken, Windows sisteminde standart masaüstü kullanım seçeneği de sunulmuştur. Bütün yazılım dilleri ile Raspberry Pi mini bilgisayarını kodlamak mümkündür.

Tez çalışmasının proje sürecinde, tedarik aşamasına gelindiği dönemde, Raspberry Pi'nin Mart 2019 tarihinde piyasaya çıkan son versiyonu Raspberry Pi 3 Model B+ idi. Dolayısıyla her yeni modelde gelişen mini bilgisayarın Türkiye'de alınabilecek son sürümü incelendi. Özellikle; kablosuz internet bağlantısı, hafıza kapasitesi ve kamera/multimedya desteği önemsenerek ürün özellikleri önceki modellerle kıyaslandığında, çalışır duruma gelen sistemin çalışma şeklinde mutlak performans iyileştirmelerine yol açabilecek değişiklikler ve geliştirmelere rastlandı. 1GB LPDDR2 SDRAM rastgele erişimli hafıza, çift bant 2.4 + 5 GHz 802.11.b/g/n/ac kablosuz yerel alan ağı, 300Mbps Gigabit, PoE HAT uyumlu ethernet, 4.2 düşük enerji bluetooth, 40 pinli GPIO, mikroSD kart girişi, HDMI, DSI ekran portu + CSI kamera portu, 4 kutuplu 3.5mm ses + kompozit video portu, 4 adet USB 2.0 + MikroUSB 5V/2,5A güç girişi, H.264, MPEG-4 1080p@30, OpenGL 2.0 multimedya özelliklerine sahip model, projenin isterlerini karşılayabilecek niteliklere sahip görülmüştür.

Tez çalışmasının proje parçası olan ve programlanarak insansız hava aracına eklenecek görüntü işleme modülü ve eklenti parçaları birer adet Raspberry Pi Kablosuz Klavye Mouse, Raspberry Pi Kablosuz Klavye Mouse, 4.3" HDMI Rezistif Dokunmatik LCD

Ekran 480×272, Raspberry Pi 3 Model B+ (Yeni Versiyon), Raspberry Pi Kamera Modülü V2 - (Yeni) bileşenlerinden oluşmaktadır.

Projede `ssd_mobilenet_v1_coco_11_06_2017` isimli model kullanılmıştır ve bu modelin `frozen_inference_graph.pb` isimli bir model grafiği mevcuttur. Model, duman görseli tanımak üzere eğitilmemiştir. Bu nedenle duman verileri içeren 100 resim google görsellerden alınarak `labelImg` isimli programda etiketlenerek `.xml` yansımaları ile birlikte bu modele eklenmiştir. Eklenen nesne modele entegre edilmiştir ve bu sırada Tensorboard üzerinden ilerlemenin durumu gözlenmiştir.

3.2.1 Raspberry pi kurulumu

Raspberry mini bilgisayarının ilk kurulumu sırasında, cihaza işletim sistemi yüklemek amacıyla SDHC uyumlu, en az 10Mb/s (Class 10) yazma hızına sahip ve 16 GB hafızalı bir microSD kart kullanılır. Tez projesinde sandisk 32 GB class10 SDHC SD kartı ve kartı bir dizüstü bilgisayardan kablo kullanmadan erişilebilir kılmak adına bir SD kart adaptör aracı (Şekil 3.1) kullanılmıştır.



Şekil 3.1 Projede kullanılan SD Kart ve Temsili ve Kart Adaptörü Temsili

Bu SD karta, işletim sisteminin imaj dosyası (ISO image file) önyüklenebilir (bootable) olarak kurulur. Bu işleme geçmeden önce Raspberry üzerinde hangi işletim sistemi ile çalışılacağına karar vermek gerekir.

Raspberry Pi bilgisayarı, Raspberry Pi vakfı tarafından oluşturulmuştur ve vakıf tarafından tüm Raspberry Pi işlemcileri ile çalışmaya uygun olduğu belirtilerek paylaşılan resmi işletim sistemi Raspbian'dır. Bu işletim sistemi Debian tabanlı olup Linux


komutlarıyla ve uyumlu programlarla sorunsuz çalışan özgün ve ücretsiz bir sistemdir. Bunun haricinde, Raspberry Pi cihazları ile çalışabilen Ubuntu Mate, Ubuntu Core, Ubuntu Server, Windows 10 IoT Core, OSMC, LibreELEC, Mozilla Web Things, PiNet, RISC OS, Weather Station, Ichigo Jam Rpi gibi farklı üçüncü parti işletim sistemi imaj dosyaları da resmi internet sayfasında indirilebilir durumda paylaşılmıştır.

Raspbian işletim sisteminin çeşitli sürümleri vardır. Sonunda 'Lite' eki gördüğünüz sistemler genellikle masaüstü arayüzü sunmayan, yalnızca konsol üzerinden çalışabileceğiniz, programlama açısından daha hızlı olan sistemlerdir ve yeni başlayanlara önerilmez. Eğer masaüstü bilgisayarında kullanmaya alışkın olduğunuz biçimde bir masaüstü grafik arayüzü görmek istiyorsanız 'Desktop' versiyonları tercih etmelisiniz.

Farklı işletim sisteminde çalışmak, bir programın ve bağlı çalıştığı kütüphanelerin ne şekilde yükleneceğini etkiler ve yüklenecek yazılımların kurulumu sırasında çalışılmakta olan işletim sistemi ile uyumlu yükleme dosyalarını bulmak gerekir.

Üçüncü parti işletim sistemleri de cihazı, en az resmi işletim sistemi Raspbian kadar sorunsuz çalıştıracaktır. Ancak Tensorflow'un ve projenin çalışır hale gelmek için gereksinim duyacağı kütüphanelerin sorunsuz yüklenmesi ve projede yazılımsal hataların giderilmesi konusunda yardım alınabilecek kaynakların çoğaltılması amaçları ile tez projesinde, bu tarz projelerde yaygın kullanılan en popüler işletim sistemi olan Raspbian kullanılmasına karar verilmiştir.

Raspbian imajını indirdikten sonra, Windows veya Linux arayüzlerinden çalışmaya alışkın olduğunuzu seçebilirsiniz. İndirme tamamlandıktan sonra SD kartı formatlamak ve işletim sisteminin ISO dosyasını Raspberry'e takıldığı anda çalıştırabilecek dosya türüne dönüştürmek için Win32DiskImager (veya aynı işlevi görecektir farklı bir yazılım da kullanılabilir) programı indirilip kurulmalıdır. Program, çalıştırıldığında (Şekil 3.2) ISO dosyasının imaj konumunu ve biçimlendirilecek hafıza kartını seçerek biçimlendirmeye başlayabileceğiniz bir arayüz sunmaktadır.




Şekil 3.2 SD Karta Önyüklenabilir ISO İmajı Yüklemeye Yarayacak Win32Disk Imager Program Çalışır Görüntüsü

Bu işlemler, işletim sisteminin .img uzantılı ISO dosyasını dolaylı olarak işlemcinin tanıyacağı biçimde SD karta aktarmada gerçekleştirilmesi gereken ön aşamalardır. Bu işlemlerle uğraşmak istemeyen ve daha büyük hafızaya sahip bir SD karta sahip kullanıcılara, NOOBS isimli Raspbian işletim sisteminin kurulu biçimde sunulduğu dosya dizini sunulmuştur. Bazı temel programların yüklü biçimde kurulduğu bu işletim sistemi sıkıştırılmış zip dosyasından çıkarıldıktan sonra, standart biçimde sağ tıklayarak biçimlendirilen SD kartın içine doğrudan aktarılır. Daha çok, yeni başlayan kullanıcılara önerilen bu sistem de yine tez projesine benzer projelerde kullanılabilir.

Daha sonra, ISO dosyası ile biçimlendirilerek veya doğrudan NOOBS içeriği aktarılacak ilk çalıştırmada kullanılmaya hazır hale getirilen SD kart, cihazın alt kısmında bulunan MICRO SD CARD girişine (Şekil 3.3) yerleştirip cihaza 2.5A 5V miktarında güç vererek ilk çalıştırma gerçekleştirilir. Bu güç akışını standart prizden sağlamak için Raspberry Pi güç adaptörü alınabilir. Buna alternatif olarak, akıllı telefonları şarj etmede kullanılan şarj aletleri de yine 5V 2.5A çıkışlı olduğundan, uygun bir ara kablo kullanılarak cihazı beslemek mümkündür. Raspberry'i mobil olarak, herhangi bir kontrol istasyonu

kullanmadan tek başına doğrudan kullanabilmek için ise taşınabilir şarj cihazları (PowerBank) kullanılabilir. Adaptör kaynağının Raspberry'e bağlanacak ucu mikroUSB girişi şeklindedir.




Şekil 3.3 Raspberry Pi Micro SD Card Girişinde Önyükleme için Hazırlanmış Olan Kart

Cihaz, tez projesinde kullanılmak üzere eklentileri ile birlikte hazırlanmıştır (Şekil 3.4) ve akıllı telefon şarj aleti adaptörü ile bir ucu USB bir ucu mikroUSB çıkışlı ara kablo kullanılarak beslenmiştir. Raspberry programlandıktan sonra, insansız hava aracına yerleştirilir ve bu aşamadan sonra bir regülatör yardımıyla insansız hava aracını bataryasından beslenir. Bu durumda cihazı manipüle edebilmek için, cihaza uzaktan bağlanmak gerekecektir. Ancak programlama esnasında kolaylık sağlaması açısından, bir takım ek parçalar satın alınmıştır.



Şekil 3.4 Raspberry Pi Modülü ve Ek Programlama Araçları


Hazırlanmış olan SD kartın takılı olduğu cihaz çalıştırıldığında, Raspbian işletim sistemi kurulum ekranı (Şekil 3.5) gelecektir. Buradan cihaza kurulması istenen işletim sistemi ve yan öğeler seçilerek kurulum sürdürülebilir. Bu seçenekler, cihaz Wi-Fi ağ seçeneğinden internete bağlanırsa çoğalacaktır. Raspbian için önerilen sistem, projede kullanılmak üzere tercih edilmiştir. Bu adımdan sonra uygun görülen şekilde işaretlenerek dil, bölge, klavye düzeni gibi bazı özelleştirme seçenekleri tanımlanarak kurulum tamamlanır. Kurulum tamamlandıktan sonra cihazı yeniden başlatılarak değişikliklerin kaydedilmesi sağlanır. İşletim sistemi kurularak çalışmaya hazır hale getirilen Raspberry Pi mini bilgisayar, bu yeniden başlatma işleminden sonra kullanıma hazır hale gelmiş olacaktır.



Şekil 3.5 Raspbian İşletim Sistemi Kurulum Seçenekleri


Raspberry Pi cihazları; USB yoluyla doğrudan kendisine bağlanan mouse ve klavye, HDMI kablosu ile doğrudan kendisine bağlanan monitör gibi dış bileşenleri otomatik olarak algılar ve bu araçlarla uyumlu çalışmaya başlar. Ancak Waveshare ekran ve kamera modülünü kullanmadan önce cihaza tanıtmak gerekir. Raspberry Pi'nin kamera modülü ile çalışmadan önce bilinmesi gereken önemli nokta, kamerayı cihaza bağlayan kalın şerit, statik elektrikten etkilenecek bozulabilmektedir. Bu nedenle satın alındığında içinde geldiği gri anti-statik torbadan çıkarılmadan önce ellerle toprağa veya topraklandığı kesin olan bir nesneye dokunulmalıdır. Örneğin, kalorifer peteğine (Radyatör) dokunmak vücuttaki statik elektriği nötrleyecektir.

Kamerayı kullanılabilir hale getirmenin ilk adımı, Raspberry Pi'ye bağlamaktır. Kameranın bağlantı ucu, beyaz şerit şeklinde uzanan kabloun ucundaki gümüş renkli pinler HDMI girişine bakacak şekilde, HDMI ve Ethernet portlarının arasındaki yuvasına (Şekil 3.6) yerleştirilmelidir.



Şekil 3.6 Kamera Modülü Bağlantı Şekli

Kameranın bağlantı kablosu, yuvasına yerleştirildikten sonra, cihaz yeniden başlatılmalıdır. Yeniden başlatma sonrası, komut istemcisi üzerinden "sudo raspi-config" komutu çalıştırılarak cihazın konfigürasyon ayarlarından arayüz seçenekleri (Şekil 3.7) seçilmelidir. Araca kamera modülü takıldıktan sonra, rezistif ekran modülü de takıldığında, Raspberry'nin açılırken bir sonsuz döngüye girdiği saptanmıştır. Bu durumun nedeni, iletken olan kamera kablosunun sıkışarak, bazı pinleri diğerleri ile etkileşim içine sokmuş olması olduğu düşünülmektedir. Bu problemde gerçekleşen çakışma durumu haricinde, Raspberry çeşitli nedenlerden dolayı kendi kendini kapatabilmektedir. Cihazın kendi kendini kapatması ile ilgili benzer problemler yaşayan kişilerin bu problemi çözmek için önerdikleri temel şey, cihazın güç kaynağının değiştirilmesidir. Böyle bir durumla karşılaşıldığında, güç kaynağınızı değiştirmeyi deneyebilirsiniz.



Şekil 3.7 Raspberry Konfigürasyon Ayarları Arayüz Görünümü

Arayüz seçenekleri arasına kamera seçeneğinin gelmiş olması beklenir. Eğer gelmemişse, "sudo apt-get update" ve "sudo apt-get upgrade" komutları art arda çalıştırılarak ve makine yeniden başlatılarak cihazın son güncellemelerden haberdar olması sağlanır. Konfigürasyon seçenekleri arasında kamera seçeneği bulunduğunda, bu ayar seçilerek kamera etkin(enable) hale getirilmelidir. Kamera etkin hale getirildikten sonra, çalışıp çalışmadığını test etmek ve fotoğraf veya video çekmek için, NOOBS sistemi içinde gelen raspistill ve raspivid isimli iki program mevcuttur. Kameranın çalışma şeklini test etmek için, "raspistill -o image.jpg" komutu ile fotoğraf çekerek kaydedilebilir, "raspivid -o video.h264 -t 10000" komutu ile video çekilerek kaydedilebilir.

Kamera modülünün yanı sıra çalışabilmesi için ekstra bir kurulum aşaması gerektiren, kendisine pinler aracılığıyla bağlanacak olan Rezistif Dokunmatik LCD Ekran bileşeninin kurulabilmesi için bir sürücü yüklenmesi gerekir. Kullanılacak ekrana uygun sürücü dosyası, cihazı ilk başlatma işleminden önce, indirilerek sıkıştırılmış halde SD karta yüklenir.

Böylece Raspberry'nin alt dizinlerinden olan /boot dizininin altında sıkıştırıldığı dosyadan çıkarılarak(unzip), dosyaların çıkarıldığı dizinde LCD ekranı etkinleştirme komutları çalıştırılabilecektir.

Ekran sürücüsünün sıkıştırılmış hali SD karta yüklendikten sonra, ekran cihaza bir numaralı pinler bir numaralı pinlere gelecek biçimde takılır. Daha sonra cihaza kurulum yapıldığında, sürücü dosyalarının yer aldığı boot klasörü içinde yüklediğimiz dosyanın da yer aldığı görülecektir. “cd /” komutu ile sürücü yazılımlarının yüklenmiş olduğu alan, çalışma dizini olarak seçilir. Burada “ls” komutu çalıştırıldığında, çalışılan dizinde bulunan tüm dosyalar listelenecektir. Önceki işlemler doğru tamamlanmışsa, dosyaların içinde boot isimli dizin, onun içinde LCD-show-master.tar.gz isimli indirmiş olduğumuz ekran sürücüsünün sıkıştırılmış dosyası mevcut olmalıdır. Dosyanın içeriğinin sıkıştırılmış halden, boot dizini altına çıkarmak için “sudo tar xvf LCD-show-master.tar.gz” komutu çalıştırılır ve LCD-show isimli dosya çıkarılır. Bu dosyayı çalışma dizini seçmek için “cd LCD-show” komutu kullanılır. Bu dizin içerisine girdikten sonra ise, “sudo LCD42-show” komutu kullanılarak sürücü kurulumu başlamış olur ve kurulum sonlandığında varsayılan görüntü çıktı birimi olarak 4.2 inç boyutundaki LCD ekran atanmış olacaktır. Görüntü çıktı birimini yeniden değiştirmek gerekirse, yine sürücü dosyalarının bulunduğu alanda, boot/LCD-show dizini içinde çalışırken, “sudo ./LCD-HDMI” komutu kullanılarak varsayılan görüntü çıktı birimi olarak HDMI bağlantısı kurulmuş olan ekran atanmış olacaktır.


3.2.2 Uzaktan raspberry kontrol

Raspberry kendi başına mouse, klavye ve ekran gibi dış bileşenlerin doğrudan bağlanabildiği, Wi-Fi bağlantısı üzerinden ihtiyaç duyulan programların indirilebildiği ve kurulumların gerçekleştirilebildiği kendi kendine yeten bir mini bilgisayardır. Ancak çoğu robotik projesinde Raspberry başka elektronik bileşenlerle bağlantılı halde etkileşim içinde kullanılır.

Mouse ve klavye bağlamak Raspberry'nin USB portlarını kullanarak cihaza bağlanabilecek azami donanım eklentisi sayısının azaltır. Bunun yanı sıra bazı bileşenler

vardır ki Raspberry'ye boş portu bulunsa dahi başka bir aracın bağlanmasını kısıtlar. Bunun en iyi örneklerinden biri tez projesinde, insansız hava aracının bataryasından beslenen Raspberry'e, portlar müsait olsa dahi bağlantılar kurulduktan sonra erişip mouse, klavye takmanın mümkün veya makul olmamasıdır. Raspberry Pi; mouse, klavye ve hatta ekran olmadan da programlanabilir. Bunu mümkün kılan üç yöntem vardır.


İlk yöntem TTL seri kablo ile bağlantı yöntemidir. Bu yöntemle bağlantı kurabilmek için Raspberry Pi üzerindeki GPIO pinleri (Şekil 3.8) kullanılır.



Şekil 3.8 Raspberry Pi Giriş ve Çıkış Bileşenleri


TTL bağlantısının kurulabilmesi için Raspberry dışında bir adet USB TTL seri dönüştürücü kablosuna (Şekil 3.9) ihtiyaç duyulur. Kablonun siyah renkli pin ucu toprak (ground), kırmızı renkli pin ucu 5V, yeşil renkli pin ucu TX, beyaz renkli pin ucu ise RX girişlerini ifade eder. Bu kablo, uzaktan bağlantı kurarak Raspberry'yi uzaktan yönetmek amacı dışında Raspberry'lerin kendi aralarında veya Arduino gibi farklı mikrodenetleyicilerle haberleşmesi için de kullanılabilir. TTL bağlantısı ile uzaktan kontrol yönteminin kullanılabilmesi için Raspberry'de seri konsolu açmak gerekir.

Bunu yapmak için, Raspberry'nin üst görev çubuğunun sol üstünde bulunan ahududu işaretinden, preferences/tercihler >> Raspberry Pi configuration/konfigürasyonu >> interfaces/arayüzler >> serial/seri bağlantı adımlarını izleyerek, seri bağlantı seçeneğini etkin (enable) hale getirmek gerekir. Bu değişiklik sonrasında sistem, değişiklikleri algılayabilmesi için yeniden başlatılmalıdır.



Şekil 3.9 Dönüştürücü Kablo ile RPi GPIO Pinlerinin Eşleşme Biçimi

Dönüştürücü kablo (PL2303), kablunun yeşil pin ucu(TX), Raspberry'nin RX pinine, kablunun beyaz(RX) pin ucu Raspberry'nin TX pinine, kablunun toprak (ground) ucu, Raspberry'nin toprak (ground) pinine gelecek şekilde (Şekil 3.9) Raspberry'e bağlanır.



Şekil 3.10 Raspberry Pi GPIO Pinleri Dizilim Şeması


Raspberry pi cihazındaki GPIO pinlerinin her birinin bir ismi ve işlevi vardır. Pinlerin işlevi ve ismi, cihazın doğrudan üzerinde yazmaz ancak Raspberry vakfının paylaşmış olduğu GPIO dizilim şemasına bakılarak hangi pinin neyi ifade ettiği anlaşılabilir.

Şemadan (Şekil 3.10) da bakıldığında görüleceği gibi, Raspberry Pi Model B+ devresi için GPIO pinlerinden 8 numaralı GPIO14 UARTT0_TXD pini bağlantı şemasındaki Rpi TX, 10 numaralı GPIO UARTT0_RXD pini ise bağlantı şemasındaki Rpi RX çıkışını ifade etmektedir. Bu şemalar yardımı ile TTL-USB seri dönüştürücü kablosu cihaza bağlanabilir. Bağlantı kurulduğunda kırmızı 5V ucu başlangıçta bağlanmaz, boşta bırakılır.

Uzaktan bağlantı, Linux ve macOS işletim sistemlerinde terminal üzerinden istemci komutları ile kurulabilirken, Windows işletim sisteminde bağlantıyı kurabilmek için Putty isimli aracı programa ihtiyaç duyulur. Putty indirilip kurulduktan ve dönüştürücü kablo bilgisayara takıldıktan sonra aygıt yöneticisinden bağlantı noktalarından (ports) dönüştürücünün Comm Port numarasına bakılır. Putty Programı açılarak (Şekil 3.11), seri haberleşme (serial) seçilir. Seri hat (serial line) kısmına dönüştürücünün Comm Port numarası, speed (bağlantı) kısmına 115200 girilir ve open/aç butonuna tıklanarak bağlantı için bir komut istemci penceresi açılır. Bu pencere açıldığında eğer Raspberry'e enerji verilmediyse siyah ekran gelir.

Kablonun bağlantı kurulurken bağlanmayarak boşta bırakılan kırmızı (5V) pin ucu Raspberry üzerindeki 2 numaralı 5V GPIO pinine takılarak, Raspberry bilgisayar

üzerinden beslenebilir ancak Raspberry yüksek akım çekebildiğinden yetersiz kalacaktır. Bunun yerine Raspberry standart mikroUSB girişi üzerinden beslenirken, bu kırmızı uç açıkta bırakılır.



Şekil 3.11 Putty Konfigürasyon Arayüzü

Raspberry Pi USB kablo ile beslenip tamamen açıldıktan sonra Putty penceresindeki siyah ekrana yazılar gelecektir. Kullanıcı adı ve şifre girilerek Raspberry’ye erişilebilir.

İkinci uzaktan bağlantı yöntemi SSH (Secure Shell) uzak sunucu bağlantı protokolü denilen kriptolanmış ağ protokolü teknolojisidir. Programlama projelerinin yürütüldüğü çalışma istasyonlarında her bilgisayarda tüm araçlar yüklü olmaz. Donanımsal ve yazılımsal açıdan tam donanımlı bir ana bilgisayar bulunur ve tüm diğer çalışanlar, bu ana bilgisayardan yürütülmesi gereken işlemlerini yürütebilmek için cihaza uzaktan bağlanır. Bu bağlanma işlemine olanak tanıyan protokol olan SSH, uzaktaki bilgisayarlar için fiziksel olarak bağlı gibi kabuk(shell) komutlarını çalıştırmaya yarar. Unix tabanlı işletim sistemlerinde, terminal komut istemcisine “ssh kullanıcıadı@hostipadresesi” komutu verilerek SSH bağlantısı kurulabilir. Bunu yapmadan önce Raspberry üzerinden SSH bağlantısını etkinleştirmek gerekir. Bunun için “sudo raspi-config” komutuyla Raspberry’nin konfigürasyon ayarlarının bulunduğu arayüze erişilir. Bu arayüz üzerinden arayüz seçenekleri/interfacing option kısmına gelerek, SSH opsiyonunu etkin (enable) hale getirmek gerekir.

Raspberry'nin SSH bağlantısı etkinleştirildikten sonra, uzaktan bağlantı komutunda host ip adresi olarak istenen, cihazın ip adresini öğrenmek gerekir. Host ip adresini keşfetmek için “ifconfig | grep inet” komutu ile Raspberry'nin ip adresi öğrenilebilir. Eğer kullanıcı adı değiştirilmediyse Raspberry'nin adı 'pi' olarak kullanılacaktır. Böylece kullanıcı adı ve host ip adresini öğrenilen cihaza, Unix tabanlı işletim sistemlerinin terminal komut istemcisinden “ssh kullanıcıadı@hostipadresisi” komutu ile bağlanılabilir.

Eğer uzaktan bağlantının kurulacağı bilgisayar Windows tabanlı bir işletim sistemine sahipse, Putty isimli programa ihtiyaç duyulur. Program indirildikten ve kurulduktan sonra, hostname isimli kısma Raspberry'nin ip adresini girerek open butonuna tıklanır. Böylece Raspberry cihazına bağlanılmış olur.

Üçüncü uzaktan erişim yöntemi ise VNC (Virtual Network Computing) sanal ağ yönetim protokolüdür. VNC protokolü güncel Raspberry cihazlarında yüklenmiş olarak gelmektedir. Kullanmadan önce arayüz seçeneklerinden, VNC seçeneğini etkin (enable) hale getirmek gerekir. Cihaza, VNC üzerinden uzaktan bağlanabilmek için RealVNC istemci programını yüklemek gerekir. Bu programı indirip kurduktan sonra, program çalıştırılarak Raspberry'nin ip adresi ile karta bağlanılır.

Tüm yöntemler içinde VNC bağlantısı yöntemi en pratik ve etkili yöntemdir. Bağlantı kurulduktan sonra, Raspberry'nin masaüstü görüntüsü RealVNC programının penceresine düşeceğinden, kontrol etmek ve üzerinde çalışmak görsel arayüzü sayesinde daha kolay ve etkili gerçekleştirilebilir.


3.2.3 Raspberry ile insansız hava aracı entegrasyonu

Raspberry Pi cihazı birçok robotik ve IoT projesinde kullanılan, programcıya mobil bir üretim ortamı sunan güçlü ve yüksek kapasiteli bir cihazdır. Raspberry Pi mini bilgisayarını insansız hava araçları ile kullanılabilir hale getirmedeki ilk adım cihazı insansız hava aracının dahili bataryasından beslenebilir biçimde sisteme bağlamak olacaktır.

Aksi taktirde, cihazı insansız hava aracının üstüne sabitlenecek bir powerbank ile beslemek gibi, kullanılabilecek diğer yöntemler aracın ağırlığını arttıracığından istenen bir özellik değildir.

Raspberry Pi'yi insansız hava aracının LiPo bataryasından çekilen elektriğin akım ve voltaj değerlerinin çok yüksek olması, cihazı araçtan doğrudan kablolama ile beslemeye engel olacaktır. Bu engelin aşılabilmesi için güç dağıtıcısı ile Raspberry'nin beslendiği giriş yuvası arasına bir regülator yerleştirilmesidir. Bunun için bir dönüştürücü pil ayarlayıcı devresi (Switching Battery BEC) kullanılır.

BEC devresinin siyah pin ucu pin uçları güç dağıtıcısının toprak (ground) ucuna, devrenin kırmızı pin ucu dağıtıcının voltaj veren ucuna, diğer taraftan devrenin üçlü ucu ise Raspberry Pi'nin 2,4 ve 6 numaralı pin girişlerine (Şekil 3.12) bağlanır.



Şekil 3.12 Batarya Ayarlayıcı Devre Dönüştürücüsü ve BEC Devresinin Bağlanacağı Raspberry Pinleri

4. ARAŞTIRMA BULGULARI

Yangın algılamada gerçek zamanlı veri akışı içinde saptama yapan sisteme rastlanmamıştır. Sistemler genelde belirli periyotlarda kontrol birimine video veya fotoğraf ögelerini yollayarak değerlendirilmesi üzerine kurulmuştur.

Duman kaynağı ile değerlendirilen girdiyi alan aracın bulunduğu konum arasındaki mesafe uzak olacağından duman görselinin boyutu ve yüksekliği perspektif açısından değişkenlik göstermektedir. Sistemlerde sağlama yapılması için tasarlanmış birden çok fazlı süreçlere de rastlanmamıştır. Bu da asılsız ihbar durumlarının kontrolünün sağlanması için beşeri kaynakların tüketilmesi zorunluluğunu doğurmaktadır. Aynı zamanda gerçekte duman olan bir veriyi algoritma duman olmayanlar sınıfına atayacak olursa bu tehdidin gözardı edilmesine yol açacaktır.

Hareketsiz gözleme dayanan yangın algılama sistemlerinin doğurduğu bir başka sorun ise, gözlem kulesinin çok yakınında veya görüş açısı dışında meydana gelen yangınların saptanamamasıdır. Yangının dumanının, gözlem aracının kadrajına girebilmesi için dahi bazı koşulların sağlanması beklenir. Bu da çoğunlukla, sabit gözleme dayalı sistemlerin gerçek hayatta kullanıldığında gerçekçi çözümler sunamaması ile sonuçlanmaktadır.

İnsansız hava araçlarının mobil yapısı sayesinde, hareket halinde duman kadraja bir değil birçok açıdan gireceği için, modelin dumanı saptama olasılığı artacaktır. Araç, yangının kaynağına yaklaşırken ve kaynaktan uzaklaşırken, sonucun teyit edilmesi için de bir fırsat doğacaktır.

Tüm bu yönlerden bakıldığında, görsele dayalı bir yangın algılama sisteminde, insansız hava araçlarının kullanılması makul ve olumlu sonuçlar doğurabilecek bir gelişmedir.

4.1 İnsansız Hava Aracı Tasarımı

Projede kullanılacak dört motorlu döner kanatlı insansız hava aracı için çerçeve (frame) tasarlanırken, aerodinamik etkisi ve ağırlık merkezi dağılımı göz önünde tutularak karbon fiber malzemeden delikli bir model tercih edilmiştir. Dron tasarımlarına bakıldığında, H tipi çerçevenin tercih edilme nedeni, güvenilir küt tabanı ve çerçeveden ayrı uzanan kolları sayesinde bu tip çerçeveye sahip dronların yük taşıma görevlerini yerine getirirken daha sağlam yuvarlanma(roll) yapma potansiyeli olarak görülebilir. H tipi dronlar keskin virajları aldıktan sonra daha kolay toparlanabilir ve gövdenin merkezine yerleştirilen batarya olası düşüşlerde daha az hasar alacağından daha uzun ömürlü olacağı öngörülebilir. Ancak projede kullanılan aracın orjinal tasarımında (Ek 1 ve Ek 2) köşesiz gövde üzerine sandviç modeli içinde elektronik aksam yerleştirilmesi planlanmıştır. Böylece denemeler ve uçuş eğitimleri sırasında elektronik aksam ve pil korunaklı bir bölmede yer alacağından X ve H tipi kasalar arasındaki en temel iki farktan ikincisi etkisiz kalmaktadır. Proje isterlerinin yerine getirilmesi sırasında yapılacak en kıvrak hamle sağa ve sola yalpa(yaw) hareketi olacaktır. Bu gereksinim düşünüldüğünde de X ve Y çerçeve kıyaslandığında H çerçeveyi makul kılan en belirgin fark da önemini yitirmiş olacaktır. Genellikle yarış dronlarında X tipi kasa kullanılmaktadır.

Aracın takip edeceği güzergahta hızlı seyretmesinin daha geniş alanda kontrol sağlayacağı göz önünde bulundurulduğunda, X tipi dronun yarış araçlarında kullanılmasına yol açan avantajları, proje aracının gövde tasarımında X tipi kasa tercih edilmesinde rol oynamıştır. Bu avantajlar; ağırlık merkezinin daha dengeli dağılması, dron hamlelerinde görev alan mekanizmaların simetrik eş çalışma prensibinde olması, kumanda ile kontrolde pilotun araç kontrol komutlarına daha kolay oryante olabilmesi gibi birkaç ana başlıkta incelenebilir. Proje aracında motorların gövdeden uzaklığı/ merkezden çerçeve kol uzunluğu 30 cm olarak tasarlandı.

Dört motorlu döner kanatlı insansız hava araçları, hafif siklet multikopterler arasında belirgin avantajlara sahiptir. En önemli avantajı motor/kanat simetrisi dolayısıyla -sabit kanatlara nazaran- stabil olmayan dron tasarımının denge handikapını minimize etmesidir. Eklenecek her bir motor, tasarıma ağırlık bindirecektir ancak aynı zamanda

motor gücünün artması dronun taşıma, hızlanma kapasitesi(tork) ve performansını doğrudan artıracığından, dört motorlu tasarım bu tezatı iyi dengeleyerek optimal sonuçlar doğuracaktır. Elektronik hız kontrol ünitesi, motor ve pervane bileşenleri dronun itki sistemini meydana getirmektedir.

Fırçasız motorlarda hız kontrolü sabit tork ile yapılabilir, sürtünme olmadığından motor; ark yapmaz, toz çıkarmaz, az ısınır ve yüksek verimde çalışır. Aracın tasarımında, dört adet 770 KV kısa şaftlı avroto fırçasız motor kullanımı uygun bulunmuştur. Her bir motorda, proje aracının tahmini ağırlığı ve olası çarpışmada oluşabilecek riskler göz önüne alınarak dayanımı yüksek plastik/naylon veya karbon fiber naylon malzemeden yapılmış dört pervane kullanılacaktır. Seçilecek pervanenin 3 kanatlı yerine 2 kanatlı, eğim açısı 4.5 "(11.43 cm) ve pervane çapı 10"(25.4 cm) olarak belirlenmiştir. Bu seçim akran yarış dronları temel alınarak gerçekleştirilmiştir. İnsansız hava aracı sisteminin itki değeri hesaplanırken d değeri pervane çapını inç birimi cinsinden simgelemektedir ve kesin olarak değeri bilinen bir değişken olan 10"(25.4 cm) olarak formüle dahil edilmiştir. RPM değeri bir dakika içinde pervanenin kaç tur atacağı sayısal değerini simgeler. Pitch değeri ise inç birimi cinsinden bir pervane turunda kat edilen yol değerini simgeler. V0 ise ileri yönlü pervane hızını m/s birimi cinsinden ifade etmektedir. İleri yönlü dinamik itki denkleminde itki değeri hesaplanırken, araçta kullanılan Avroto M2814-11S motorların test verileri kullanılmıştır. İleri yönlü dinamik itki kuvvetinin hesaplanmasında,

$$f(x) = 1,225 \cdot \frac{\pi (0,0254 \cdot d)^2}{4} + \left[\left(RPM \cdot 0,0254 \cdot pitch \cdot \frac{1}{60} \right)^2 - \left(RPM \cdot 0,0254 \cdot pitch \cdot \frac{1}{60} \right) \cdot v_0 \right] \cdot \left(\frac{d}{3,29546 \cdot pitch} \right)^{1,5}$$

Formülü kullanılmıştır.

Çizelge 4.1 Sitesinden Alınan Avroto 2814-11s Test Verileri
(<http://www.flybrushless.com>)


Propeller	Gear Ratio	Volts	Amps	Watts	RPM	Speed (mph)	Thrust (g)	Thrust (oz)	RPM as % of Kv*V
APC SF 10x4.7	1	12.24	14.03	171	7470	33.2	1020	35.98	79%
APC SF 10x4.7	1	12.24	13.78	168	7350	32.7	1030	36.33	78%
APC SF 10x4.7	1	12.29	10.31	126	6630	29.5	820	28.92	70%
APC SF 10x4.7	1	12.29	10.13	124	6630	29.5	813	28.68	70%
APC SF 10x4.7	1	12.33	7.29	89	5850	26.0	620	21.87	62%
APC SF 10x4.7	1	12.33	7.21	88	5820	25.9	620	21.87	61%
APC SF 10x4.7	1	12.35	5.37	66	5220	23.2	488	17.21	55%
APC SF 10x4.7	1	12.35	5.41	66	5220	23.2	490	17.28	55%
APC SF 10x4.7	1	12.37	4.07	50	4650	20.7	380	13.40	49%
APC SF 10x4.7	1	12.37	4.09	50	4650	20.7	377	13.30	49%
APC SF 10x4.7	1	12.4	2.78	34	3930	17.5	263	9.28	41%
APC SF 10x4.7	1	12.4	2.83	35	3930	17.5	261	9.21	41%
APC SF 10x4.7	1	12.42	1.67	20	3030	13.5	146	5.15	32%
APC SF 10x4.7	1	12.42	1.68	20	2940	13.1	139	4.90	31%
APC SF 10x4.7	1	12.44	0.83	10	1530	6.8	33	1.16	16%
APC SF 10x4.7	1	12.44	0.83	10	1590	7.1	38	1.34	17%
APC SF 11x4.7	1	12.18	18.2	221	6840	30.4	1241	43.77	73%

Tablodaki (Çizelge 4.1) verilere göre aracın motor başına düşen itki kuvveti 35.98 OZ kabul edilecektir. Bu da aracın yaklaşık 1 kiloya kadar azami yük taşıma kapasitesinin olacağını ifade etmektedir.

Denklemden anlaşılacağı üzere bir insansız hava aracının ileri yönlü dinamik itki kuvveti ve dolayısıyla taşıma kapasitesi araçta kullanılan pervanelerin boyutuna ve motorun gücüne bağlı olarak değişir. Her görev için kullanılması ideal olan itki birimlerinin seçilmesi, aracın pilini verimli kullanma seviyesinden dengeli uçuş sağlama kapasitesine birçok performans ögesini etkileyecektir. Bu nedenle tedarik öncesinde alınacak birimler seçilirken görev isterlerinin ve sistemin geri kalan parçalarının nitelikleri ve birbiriyle uyumunun iyi analiz edilmesi önemlidir.

4.2 İnsansız Hava Aracının Modellenmesi

Aracın özgün bir tasarıma sahip olması, projede hedeflenen ve gerçekleştirilen temel amaçlardan biridir. Aracın alt sistemlerini (Raspberry Pi, Kamera Modülü, İniş Takımı, Batarya, 4 ESC vs.) dengeli ve korunaklı biçimde taşıyabilmesi için sandviç modeli denen ortası boş iki plakanın paralel yerleştirilmesi ile meydana gelen model uygun bulunmuştur. Aerodinamik unsurlar göz önüne alınarak aracın sandviç modeli, delikli gövde tasarımı (Şekil 4.1) ile desteklenmektedir.



Şekil 4.1 (solda)Projede Kullanılan İnsansız Hava Aracının 3D SOLIDWORKS Modeli ve (sağda) aracın son hali

Araç meydana getirildikten sonra, pili kasanın üstüne ve altına monte ederek iki şekilde de uçuş denemeleri yapıldı. Döner kanatlı insansız hava araçlarında yük taşıma mekanizmasının çalışma prensibi, itki birimlerinin aşağı yönlü meydana getirdikleri havayı itme kuvvetine dayanmaktadır. Böylece pervanelerin birbiri ile veya başka bir nesne ile etkileşime gireceği her tasarım, aracın dengesini ve performansını olumsuz yönde etkilemektedir. Bu durum test sonuçlarında gözlemlendikten sonra, bataryalar gövdenin altına yerleştirilmiştir. Uçuş testleri sırasında pervane dışında kayıp verilmemiştir.

4.3 İnsansız Hava Aracının Yazılım Boyutu

Aracın donanımsal açıdan gerçekleşmesi, yalnızca pervanelerinin dönmesine böylece aracın dengeden yoksun biçimde havalanmasına yarayacaktır. Kumanda komutlarına itaat eden bir itki sistemi ve stabil uçuş için gerekli olan temel beceri olan pervanelerin senkron biçimde çalışması ancak uçuş kontrol kartı yazılımı ile tetiklenebilir.

Uçuş kontrol kartlarının üzerlerinde kendi uçuş kontrol yazılımları bulunur ve bu projede Naza V2 uçuş kartı kullanılmıştır. Uçuş kontrol kartı kumanda ile aracın arasındaki iletişime aracı olsa da otonom uçuş için bir de üzerinden manuel olarak rota belirlenebilen, araca pilot olmadan komutlar vermeye yarayan, uçuş kontrol kartı ile uyumlu olarak çalışabilen bir arayüz uygulaması kullanılmalıdır ve tez projesinde DJI Ground Station adlı program kullanılmaktadır.

Aracın yazılım yoluyla manipüle edilebilmesi için, uçuş kontrol kartı ile uyumlu çalışabilen aynı zamanda yapay zeka ve görüntü işleme algoritmalarının çalışmasına olanak tanıyan kütüphanelerin yüklenebildiği ve yürütülebildiği bir mikrodenetleyiciye ihtiyaç duyulmuştur. Piyasada bu iş için kullanılan çeşitli modüler cihazlar mevcuttur ve tez projesinin programlanmasında Raspberry Pi 3 model B+ mikrodenetleyicisinin kullanılmasına karar verilmiştir. İşlemci, Python dili ile Tensorflow kütüphanesi kullanılarak duman görselini tanımak üzere yapay öğrenme metotları ile programlanmıştır. Raspberry Pi, SSH ve VNC uzaktan bağlantı protokolleri kullanılarak uzaktan yönetilebilmektedir. Tensorflow, OpenCV, lxml, Matplotlib gibi kütüphaneler, Raspberry cihazına da kurularak, nesne tanıma uygulamasının cihaz üzerinde çalışması sağlanmıştır.

5. TARTIŞMA VE SONUÇ

Eğitilen sistemin hızlı ve hata oranı düşük sonuçlar verecek biçimde eğitildiğinin matematiksel değerlendirmeler sonucunda saptandığına dair istatistikler ve sonuçlar bu bölümde yer almaktadır. Tez projesinde eğitilmek üzere Tensorflow kütüphanesinde yer alan ön-eğitilmiş modeller barındıran Model Zoo isimli denetimli derin öğrenme ekolünün alt modeli olan ssdlite_mobilenet modeli örnek alınmıştır. Alt modeller arasında bir tür denge yaratan hız-kesinlik takası mevcuttur. Model seçerken dikkat edilmesi gereken kriter, modelin hangi amaçla kullanılacağıdır. Çünkü programlamada hep bazı şeyleri iyileştirirken bir takım şeylerden feragat etmeyi zorunlu kılan bir takas (trade-off) dengesi mevcuttur.

Gerçek zamanlı nesne tanıma uygulamasında modelin hızı ön plandayken doğruluk oranı daha geri planda kalmaktadır. Model zoo isminden yola çıkılarak, alt modellerin her biri (accuracy) kesinlik ve hız bakımından birbiriyle kıyaslanarak birer hayvana benzetilebilir. Bu bakımdan değerlendirildiğinde, RCNN NAS file, RCNN-Inception boz ayıya, MobileNetSSD aslana ve SSD Lite-MobileNET kaplana benzetilebilir. Aynı eğitim verisi üzerinde çalışılarak bu modellerin hız ve doğruluk kıyaslaması, kaynak paylaşım merkezinde yer almaktadır (Çizelge 5.1).


Çizelge 5.1 Model Zoo Alt Modellerinin Hız ve Doğruluk Karşılaştırması

Modelin Adı	Hızı	Hatalı Sonuç Sayısı
ssdlite_mobilenet_v2_coco	27	22
ssd_mobilenet_v2_coco	31	22
ssd_inception_v2_coco	42	24
faster_rcnn_inception_v2_coco	58	28
faster_rcnn_nas	1833	43

Projede, COCO eğitim seti ile eğitilmiş olan modeller araştırılarak, Raspberry üzerinde gerçek zamanlı duman verisi üzerinde çalışırken en uygun sonucu vermesi en muhtemel görünen ssdlite_mobilenet modeli modifiye edilerek kullanıldı.

Kullanılan modelin uygunluğu değerlendirilirken, her modelin her veri setinde aynı hız ve doğruluk oranı ile çalışamayacağı, renk niteliğini temel alan bir modelin, arkaplandan kendini belirgin biçimde ayıran renkteki nesneleri ayırt etmede gösterdiği başarıyı, arkaplanla birbirine çok yakın renkteki nesneler üzerinde gösteremeyeceği göz önünde bulundurulmalıdır.


İlk olarak, duman görselini tanıma yetisi kazandırmak adına, açık kaynaklı google görsellerden alınan 100 duman görseli, labelImg (Şekil 5.1) isimli programda etiketlenerek ve %10 test verisi %90 eğitim verisi olmak üzere segmente edilerek, nesne tanıma amacı ile denetimli öğrenme yürütülecek modele eklenmiştir.



Şekil 5.1 Derin Öğrenmede Ön İşleme Aşamasında Kullanılan LabelImg Programı

Modele eklenen duman verisi ile bir eğitim kaydı oluşturulur ve bu aşamadan sonra, modeller içinden kullanılan modelin alt dizininde yer alan config dosyasına duman kriteri eklenerek model konfigürasyonu güncellenir. Bu süreç esnasında, eğitim verisi işlenirken Tensorboard üzerinden eğitim performansı, Tensorboard'daki total loss fonksiyonundaki değişim (Şekil 5.2) üzerinden incelenmiştir. Tensorboard, Tensorflow kullanılarak yaratılmakta olan sinir ağının yapısının web tarayıcısı üzerinden incelenebildiği bir arayüzdür.

Burada yürütülen eğitim işlemi her bir iterasyonda test verisini ne kadar doğru adlandırıyor bu bilgi doğrultusunda bir toplam kayıp grafiği (Şekil 5.2) oluşturulur. Bu grafik, azalmayı bıraktığında eğitim faaliyeti de programcı tarafından durdurulur.

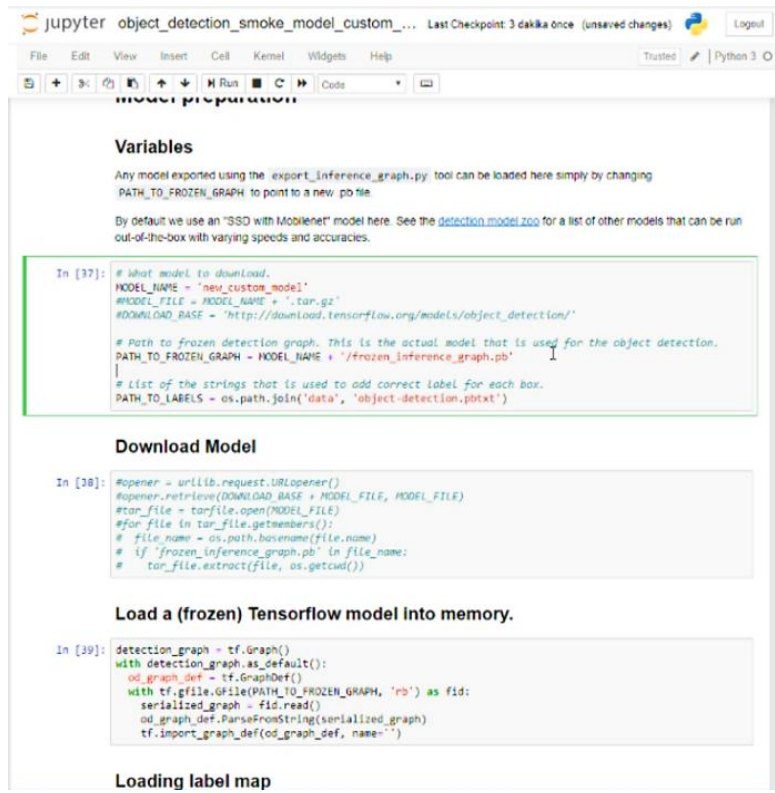


Şekil 5.2 (solda) Modelin Eğitim Aşamasında Tensorboard Sunucusunda Meydana Gelen (sol üstten, sağ alta sırasıyla) Oluşan (a)Sınıflandırma Kaybı, (b)Yerleştirme Kaybı,(c) Toplam Kayıp ve (d) Devamlılık Kaybı Grafikleri

Eğitim sırasında, bazı kontrol noktaları meydana gelir. Bu kontrol noktalarında, model dizininde bir takım .ckpt uzantılı semantik açıdan insan algısına anlamsız gelebilecek ancak makine açısından verilerin değerlendirmelerinin yer aldığı veri kayıtları tutulur. Modelin eğitimini sürerken, hata oranındaki düşme ivmesinin 112. kontrol noktasında ciddi miktarda düştüğü gözlemlenmiştir. Eğitim sürecini kısa tutmak, sistemin yeterince öğrenememesine, eğitim sürecini olması gerekenden uzun tutmaksa, sistemin ezberleme eğilimi göstermesine yol açacaktır. Bu sebeple dramatik ölçüde düşüş gözlenen toplam

kayıp grafiğinde artık eğitim süresi arttıkça kayıp sabit kalmaya yaklaşırsa, eğitim sonlandırılmalıdır. Böylece sistemin eğitilmesi 4.7764 kayıp oranında, 33. Adım, 112. kontrol noktasında sonlandırılmıştır.

Bunun ardından, etiket verilerinin ve modelin /frozen_inference_graph.pb isimli artık eğitmenin mümkün olmadığı modelin son halinin temel bilgilerinin bulunduğu dizinlere birer yol bağlantısı eklenir ve kod, yeni modele uyarlanır (Şekil 5.3). Yeni model kullanılmaya hazır hale gelmiştir.



```
object_detection_smoke_model_custom_... Last Checkpoint 3 dakika önce (unsaved changes) Logout

File Edit View Insert Cell Kernel Widgets Help Trusted Python 3

model preparation

Variables
Any model exported using the export_inference_graph.py tool can be loaded here simply by changing
PATH_TO_FROZEN_GRAPH to point to a new pb file

By default we use an SSD with Mobilenet model here. See the detection_model_zoo for a list of other models that can be run
out-of-the-box with varying speeds and accuracies.

In [37]: # What model to download.
MODEL_NAME = 'new_custom_model'
MODEL_FILE = MODEL_NAME + '.tar.gz'
DOWNLOAD_BASE = 'http://download.tensorflow.org/models/object_detection/'

# Path to frozen detection graph. This is the actual model that is used for the object detection.
PATH_TO_FROZEN_GRAPH = MODEL_NAME + '/frozen_inference_graph.pb'

# List of the strings that is used to add correct label for each box.
PATH_TO_LABELS = os.path.join('data', 'object_detection.pbtxt')

Download Model

In [38]: #opener = urllib.request.URLopener()
#opener.retrieve(DOWNLOAD_BASE + MODEL_FILE, MODEL_FILE)
#tar_file = tarfile.open(MODEL_FILE)
#for file in tar_file.getmembers():
#    file.name = os.path.basename(file.name)
#    if 'frozen_inference_graph.pb' in file.name:
#        tar_file.extract(file, os.getcwd())


Load a (frozen) Tensorflow model into memory.

In [39]: detection_graph = tf.Graph()
with detection_graph.as_default():
    od_graph_def = tf.GraphDef()
    with tf.gfile.GFile(PATH_TO_FROZEN_GRAPH, 'rb') as fid:
        serialized_graph = fid.read()
        od_graph_def.ParseFromString(serialized_graph)
        tf.import_graph_def(od_graph_def, name='')

Loading label map
```

Şekil 5.3 Özelleştirilmiş Yeni Modelin Entegrasyonu

Sonuç olarak programda kullanılan ssdlite_mobilenet modeline duman (feature) tanıma niteliği eklenmiş ve hatasız olarak çalıştırılmıştır (Şekil 5.4).



Şekil 5.4 Yeni Modelin Duman Görselini Değerlendirmesi


Duman görselinin %98 duman olduğunu söyleyen model doğru ve gerçek değeri tutturma açısından başarılı bulunmuşken, modele girdi olarak verilen görsel duman değilken de modelin, görseli oldukça yüksek bir doğruluk oranı ile duman sınıfına atadığı gözlenmiştir. Bu da yanlış alarm oranının yüksek olacağının dolayısıyla modelin daha detaylı eğitilmesi gerektiğinin bir sinyalidir.

Diğer taraftan gerekli kurulumlar gerçekleştirildikten sonra ssdlite_ mobilenet nesne tanıma modeli Raspberry pi üzerinde çalıştırılarak sonuçlar karşılaştırıldı. Kumanda nesnesinin masaüstü bilgisayarında ve Raspberry üzerinde (Şekil 5.5) çalışan çıktıları ile, cep telefonu nesnesinin masaüstü bilgisayarında ve Raspberry üzerinde (Şekil 5.6) çalışan çıktıları karşılaştırıldı.

Kumanda ve cep telefonu görselleri üzerinden raspbian işletim sistemi kullanılan Raspberry Pi üzerinde ssdlite_ mobilenet modeli baz alınarak geliştirilen uygulamada alınan sonuçlar ve Windows10 işletim sistemi kullanılan masaüstü bilgisayarında, cihazlar arasındaki ciddi sistem gücü farkı, nesne tanımadaki doğruluk oranına


yansımamıştır. Bu da projenin sürdürülmesinde önemli rol oynamıştır. VNC veya SSH bağlantısı kullanılarak uzaktan bağlanılan Raspberry Pi, uçuş sürecinde yerden kontrol edilebilir ve sonuçlar masaüstünden görüntülenebilir. İnsansız hava aracından BEC regülatörü yardımı ile beslenen cihazın, masaüstünde yürütülen işlem sonuçları ile kıyaslandığında göstermiş olduğu performans insansız hava aracı üzerinde duman tanıma esnasında masaüstü bilgisayarından daha iyi sonuçlar göstereceğini vaat etmektedir.

Masaüstü bilgisayarında eğitilen modelin frozen_graph grafiği, eğitimi durdurulan modelin kullanılmaya hazır haldeki versiyonudur. Bu ve modelin kullanılmaya hazır halde üretildiği klasör, herhangi başka bir platforma taşınarak kullanılabilir. Bu, tez projesi için büyük avantaj teşkil etmektedir. Çünkü modelin eğitilmesi çok uzun süren ve çok güçlü sistem özelliklerine sahip bir altyapı gerektiren bir iştir.



Şekil 5.5 (solda)Masaüstünde Çalışan Modelin(ssd_mobilenet) Kumanda Doğruluk Oranı ve (sağda) Raspberry Pi Üzerinde Modelin (ssdlite_mobilenet) Kumanda Doğruluk Oranı

Bir model masaüstü bilgisayarında çalıştırıldığında, modelin nesne tanımada gösterdiği başarı, aynı nesneyi tanımadan Raspberry üzerinde gösterdiği başarı ile tamamen aynı olacaktır. Bu durum benzer projeler için de kullanılacak modelin masaüstü bilgisayarında eğitilmesine olanak tanır. Böylece, yüksek performansa, alana ve zamana gerek duyan eğitim aşaması hızlandırılabilir.




Şekil 5.6 (solda) Masaüstünde Çalışan Modelin(ssd_mobilenet) Cep Telefonu Doğruluk Oranı ve (sağda) Raspberry Pi Üzerinde Modelin (ssdlite_mobilenet) Cep Telefonu Doğruluk Oranı


Modelin masaüstü bilgisayarında eğitildikten sonra Raspberry üzerinde çalıştırıldığında nesnelerin tanınmasındaki doğruluk oranı değişmediği test edilerek gözlemlenmiş, model eğitimleri her seferinde masaüstü bilgisayarında yürütülmüştür.

Modelin sorunsuz çalıştığı doğrulandıktan sonra, modelin duman nesnesini tanıması ve duman nesnesini tanımadaki doğruluk oranının artırılması adına kullanılacak eğitim veri setinin modele tanımlanmasından önce gerçekleştirilen, veri setinin eğitim ve test verisi olmak üzere ikiye ayrılmasında gözetilen yüzde oranının değiştirilerek, sonuçların kıyaslanması yoluyla bir çeşit optimizasyon çalışması yürütülmüştür. Çalışılan verilerin ayrılmasında verinin %90 eğitim, %10 test verisi; %80 eğitim, %20 test verisi; %70 eğitim, %30 test verisi; %60 eğitim, %40 test verisi olmak üzere dört farklı oran kullanılarak meydana getirilen dört farklı model, aynı deneme resimleri üzerinde çalıştırılmış ve test sonuçları değerlendirilmiştir. Model oluşturma esnasında web tarayıcısı (browser) üzerinden yürütülen Tensorboard sunucusu üzerinden, eğitim süreci kayıp grafikleri kaydedilmiş ve karşılaştırılmıştır.


Loss/classification_loss
tag: Losses/Loss/classification_loss




Loss/classification_loss
tag: Losses/Loss/classification_loss



Loss/classification_loss
tag: Losses/Loss/classification_loss




Loss/classification_loss
tag: Losses/Loss/classification_loss



Şekil 5.7 (sol üstten sağ aşağı sırasıyla)(a)%60 Eğitim %40 Test Verisi Üzerinde Eğitilen Model M4, (b)%80 Eğitim %20 Test Verisi Üzerinde Eğitilen Model M3, (c)%70 Eğitim %30 Test Verisi Üzerinde Eğitilen Model M2, (d)%90 Eğitim %10 Test Verisi Üzerinde Eğitilen Model M1 eğitilirken gözlemlenen Tensorboard Sınıflama Kayıp Grafikleri

Sınıflama hatası, bir modelin yeni gelen bir nesneyi gerçekte ait olduğu sınıfa koyma yetisini ölçer. Modelin başarısı ile sınıflama hatası ters orantılı olarak değişim göstermektedir. Modeller arasında (Şekil 5.9) altı bin iterasyon sonunda toplam hata değerinin en yüksek oranda düştüğü gözlenen model M4 modeli olmuştur. Toplam kayıp yaklaşık 1.6 civarına düşene kadar eğitim dört modelde de sürdürülmüştür. Eğitim verisine ayrılan resim sayısı arttıkça, Tensorboard üzerine yansıyan toplam kayıp grafiğinde ardışık zaman aralıklarında (epoch) dalgalanmaların arttığı gözlemlenmiştir.



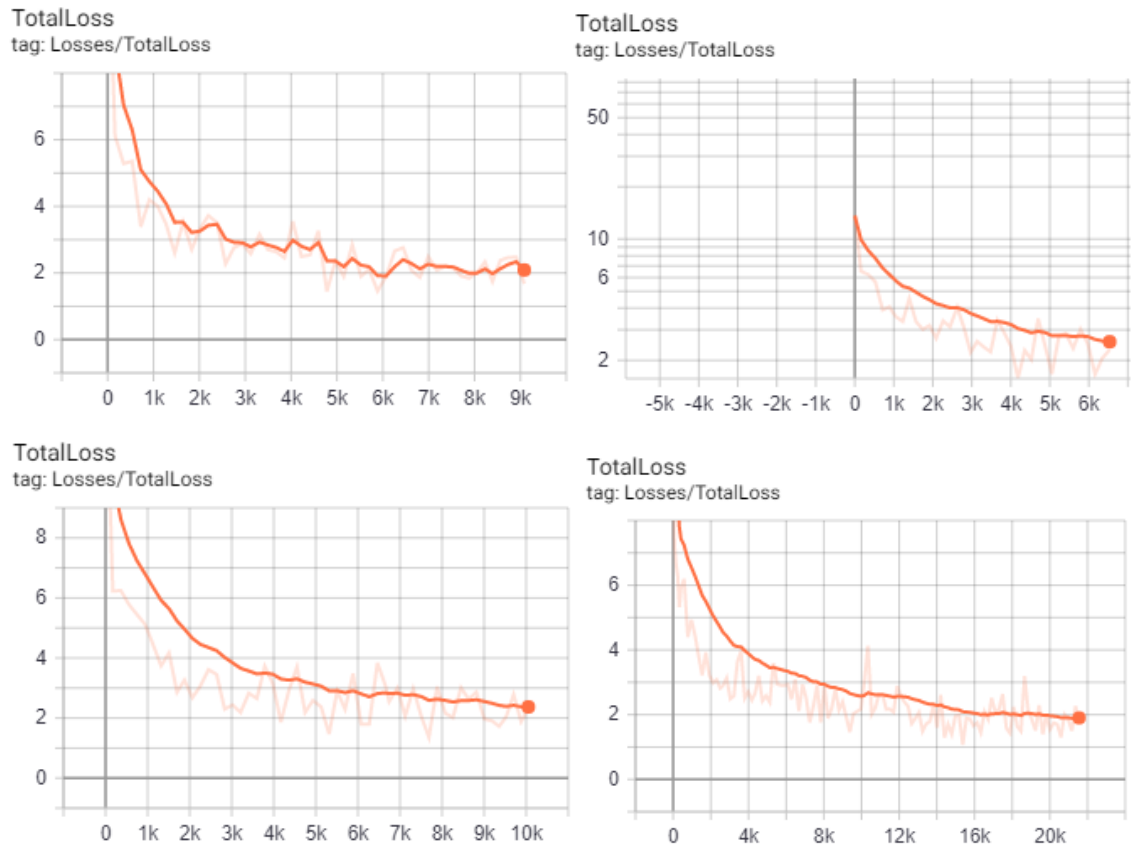
Şekil 5.8 (sol üstten sağ aşağı sırasıyla)(a)%60 Eğitim %40 Test Verisi Üzerinde Eğitilen Model M4, (b)%80 Eğitim %20 Test Verisi Üzerinde Eğitilen Model M3, (c)%70 Eğitim %30 Test Verisi Üzerinde Eğitilen Model M2, (d)%90 Eğitim %10 Test Verisi Üzerinde Eğitilen Model M1 eğitilirken gözlemlenen Tensorboard Yerleştirme Kayıp Grafikleri

Yerleştirme hatası, bir modelin sınıflandırdığı nesneyi gerçekte ait bulunduğu lokasyonda işaretleme yetisini ölçer. Modelin başarısı ile yerleştirme hatası da ters orantılı olarak değişim göstermektedir. Modeller arasında (Şekil 5.8) sekiz bin iterasyon sonunda yerleştirme hata oranının en yüksek oranda düştüğü gözlenen modeller birbirine çok yakın değerlerle M3 ve M4 modelleri olmuştur.

Benzer şekilde, eğitilen modellerin performansını ölçmeye yarayan farklı kayıp grafikleri Tensorboard sunucusunda, modelin eğitilmesiyle eş zamanlı olarak oluşmayı sürdürür. Böylece, eğitimi gerçekleştiren kişi modeli eğitmeyi ne zaman bırakması gerektiğine karar verebilmektedir. İdeal olan, kayıp oranlarının artık düşmeyi bıraktığı noktada

eğitimin durdurulmasıdır. Fazla eğitim ezberlemeye, az eğitim ise yanlış sınıflamalara yol açabilmektedir.

Kayıp grafikleri içinde en genel sonucu ifade eden, toplam kayıp grafiğidir. Eğitim sürecinin başarısı genel anlamda toplam kayıp grafiklerinden takipe edilir. Dört modelin toplam kayıp grafiğine bakıldığında (Şekil 5.9) altı bininci iterasyon sonunda en düşük toplam kayıp M3 modelinde gözlenmiştir.



Şekil 5.9 (sol üstten sağ aşağı sırasıyla)(a)%60 Eğitim %40 Test Verisi Üzerinde Eğitilen Model M4, (b)%80 Eğitim %20 Test Verisi Üzerinde Eğitilen Model M3, (c)%70 Eğitim %30 Test Verisi Üzerinde Eğitilen Model M2, (d)%90 Eğitim %10 Test Verisi Üzerinde Eğitilen Model M1 eğitilirken gözlemlenen Tensorboard Toplam Kayıp Grafikleri

Kayıp grafikleri değerlendirilirken elde ettiğimiz en düşük kayıp değerine sahip modele en başarılı model demek doğru olmaz. Bu, yalnızca o modelin diğer modellerden daha çabuk eğitilebildiğini gösterebilir.

Eğitim her modelde farklı sürede ve farklı iterasyon sayısında sonlandırılmıştır. Her bir modelin optimuma ulaştığı noktaya kadar eğitim sürdürüldüğünden, sonuçlar karşılaştırılırken de eğitimlerin bitirildiği anki kayıp değerlerini karşılaştırmak, görece doğru kıyaslama parametresi sayılabilir.

Tensorflow'un CPU ve GPU üzerinde çalışan iki versiyonu mevcuttur. Model iki şekilde de eğitilmiştir. Aynı veri üzerinde çalışan aynı model, CPU üzerinde yürütülen eğitim işleminin 10 saat 32 dakika 54 saniye içinde geldiği noktaya, GPU üzerinde 1 saat 39 dakika 47 saniyede gelebilmiştir. Bu da, görsel veriler üzerinden yürütülen derin öğrenme algoritmalarının GPU üzerinde yürütüldüğü durumlarda, CPU ile kıyaslandığında modelin 6,34 kat daha hızlı eğitildiği gözlemlendi.

Değişen eğitim ve test verilerinin ayrılma yüzdesi ile eğitilen dört farklı model arasında bir seçim yapılması için aynı kontrol grubu üzerinde yürütülen dört model üzerinde bir takım analiz işlemleri yürütülmüştür. Modellerin farklı bakımlardan tahmin başarısı ölçülmüş, modeller birbirleri ile kıyaslanarak içlerinden biri kullanılmak üzere tercih edilmiştir. Tercih edilen model %70 eğitim, %30 test verisi ile eğitilmiş olan üçüncü modeldir.

Eğitim ve test verilerinin ayrılma yüzdesi bakımından dört ayrı model çıkarılarak aynı kontrol grubu üzerinde (Şekil 5.10) yürütüldü. Kullanılan modellerin sınanması sonucunda elde edilen matematiksel bulgular, modellerle ilişkili çıktı sonuçlarının yer aldığı çıktı tablosuna (Çizelge 5.2) kaydedildi. Tablolarda P,M,N,O ve B bilinenleri ile, her $p_x \in P$ için $P=\{p_1,p_2,p_3,p_4,p_5,p_6,p_7,p_8,p_9,p_{10}\}$ pozitif görseller dizisini, her $n_x \in N$ için $N=\{n_1,n_2,n_3,n_4,n_5,n_6,n_7,n_8,n_9,n_{10}\}$ negatif görseller dizisini ve her $m_x \in M$ için $M=\{m_1,m_2,m_3,m_4\}$ eğitim ve test verilerinin ayrılma yüzdesine göre m_1 : %90 eğitim, %10 test verisi ile eğitilmiş, m_2 : %80 eğitim, %20 test verisi ile eğitilmiş, m_3 : %70 eğitim, %30 test verisi ile eğitilmiş, m_4 : %60 eğitim, %40 test verisi ile eğitilmiş dört modeli ifade etmektedir. Bunun yanı sıra, K kontrol grubu dizisi hem N negatif verileri hem de P pozitif verileri içermekte,

$$B(m,k) = \begin{cases} 0 & \text{duman yok } D' \\ 1 & \text{duman var } D \end{cases} \mid m \in M, k \in K$$

B operatörü parametre olarak verilen modeli ve kontrol grubu dizisinin elemanı olan görsel veriyi alan ve ‘var’ D veya ‘yok’ D' ikili (binary) sonucundan birini döndüren, söz konusu kontrol ögesinde aranan duman görselinin yürütülen modelin sonucuna göre bulunma durumunu ifade eden bir işlemdir. O operatörü ise,


$$O(m, k) = \begin{cases} 0 & \text{duman yok} \\ 1 & \text{duman var } B\% \end{cases} \mid m \in M, k \in K$$

duman algılandıysa, kontrol grubunda bulunan ve operatörün parametre olarak aldığı görsel veride rastlanan duman ögesinin, söz konusu modele göre duman olma olasılığını yüzde cinsinden B% olarak ifade etmektedir.

Çizelge 5.2 Kontrol Grubu Üzerinde Yürütülen Dört Modelin Çıktı Sonuçları

k_x	$B(m_1, k_x)$	$O(m_1, k_x)$	$B(m_2, k_x)$	$O(m_2, k_x)$	$B(m_3, k_x)$	$O(m_3, k_x)$	$B(m_4, k_x)$	$O(m_4, k_x)$
p ₁	Var	91%	Var	98%	Var	97%	Var	76%
p ₂	Yok	-	Var	92%	Var	89%	Yok	-
p ₃	Yok	-	Var	93%	Var	95%	Yok	-
p ₄	Yok	-	Var	90%	Var	97%	Var	81%
p ₅	Yok	-	Var	95%	Var	60%	Var	82%
p ₆	Yok	-	Var	99%	Var	93%	Var	75%
p ₇	Var	93%	Var	85%	Var	90%	Var	98%
p ₈	Var	99%	Var	98%	Var	66%	Yok	-
p ₉	Var	88%	Var	99%	Var	92%	Var	64%
p ₁₀	Yok	-	Var	95%	Var	95%	Var	72%
n ₁	Yok	-	Var	88%	Yok	-	Var	86%
n ₂	Yok	-	Var	81%	Var	97%	Yok	-
n ₃	Var	82%	Var	54%	Yok	-	Yok	-
n ₄	Yok	-	Yok	-	Yok	-	Yok	-
n ₅	Var	99%	Var	97%	Var	75%	Var	94%
n ₆	Yok	-	Var	63%	Yok	-	Var	70%
n ₇	Var	89%	Var	86%	Yok	-	Yok	-
n ₈	Yok	-	Var	92%	Var	95%	Yok	-
n ₉	Yok	-	Var	62%	Yok	-	Yok	-
n ₁₀	Yok	-	Var	66%	Yok	-	Yok	-

Kontrol grubuna eklenecek görsel veriler seçilirken, pozitif görseller için arkaplanı ve dumanın rengi ve dağılım şekli bakımından birbirinden ciddi ölçüde farklı görseller, negatif görseller için ise dumana en çok benzeyen ağaçlık alan, kumsala vuran köpüklü dalgalar, lavanta bahçesi, perde, bulutlar ve gri ağırlıklı görseller tercih edilmiştir (Şekil 5.10).



Şekil 5.10 Kontrol Grubu

Derin öğrenme modellerinin çalışma başarısı değerlendirilirken kullanılan bazı temel ölçü türleri bulunur. Bunlar toplam doğruluk, pozitif yorum gücü, negatif yorum gücü, duyarlılık, F-değerlendirme ve özgüllük değerleridir. Bu değerler hesaplanırken, modellerin DP: doğru-pozitif (TP: true-positive), DN: doğru-negatif (TN: true-negative), YP: yanlış-pozitif (FP: false-positive) ve YN: yanlış-negatif (FN: false-negative) sonuç sayısı kullanılır. Doğru-pozitif ifadesi tez projesinde yürütülen çalışmanın yer aldığı örnek uzayda, gerçekte duman içeren görsel veriler için model tarafından da duman içerdiği sonucu çıkarılan işlem sayısını ifade etmektedir.

Doğru-negatif, gerçekte duman içermeyen ve model tarafından da duman içermediği saptanan görsel verilerin sayısını; yanlış-pozitif, gerçekte duman içermediği halde, modelin duman içeriyormuş gibi sınıfladığı görsel verilerin sayısını; yanlış-negatif ise, gerçekte duman içerdiği halde model tarafından duman içermiyormuş gibi sınıflanan görsel veri sayısını nitelemektedir.

Tahmin değerleri tablosunda (Çizelge 5.3), $DP(m \mid m \in M)$ işlemi girdi modelinin doğru-pozitif sayısını, $DN(m \mid m \in M)$ doğru-negatif sayısını, $YP(m \mid m \in M)$ yanlış-pozitif sayısını, $YN(m \mid m \in M)$ yanlış-negatif sayısını ifade etmektedir.

Çizelge 5.3 Kontrol Grubu Üzerinde Yürütülem Dört Modelin Tahmin Değerleri

M_x	$DP(M_x)$	$YP(M_x)$	$DN(M_x)$	$YN(M_x)$
M_1	4	3	7	6
M_2	10	9	1	0
M_3	10	3	7	0
M_4	7	3	7	3

Doğru-pozitif ve doğru-negatif değerlerin yüksek olması, modelin gerçeğe uygun sonuçlar çıkardığını göstermektedir. Yanlış-pozitif sayısı çok olan modeller, yangın olmadığı halde itfaiye biriminin tetiklenme ihtimalinin yüksek olduğu, yanlış-negatif sayısı çok olan modeller ise yangın olduğu halde yangını göremeyerek ihmal durumuna yol açabilecek modellerdir denebilir. Bu durumda, kullanılacak modele karar verilmeden önce bu tür bir sayısal analizin yürütülmesi, projenin verimi açısından büyük önem taşımaktadır. Dört model için de, çıktı tablosunda (Çizelge 5.4) kaydedilen değerler kullanılarak hazırlanmış olan tahmin değerleri tablosunun (Çizelge 5.3) sonuçları temel alınarak, modellerin toplam doğruluk, pozitif yorum gücü, negatif yorum gücü, duyarlılık, F-değerlendirme ve özgüllük değerleri hesaplanmıştır. Toplam doğruluk değeri (accuracy), değerlendirme ölçütleri arasında en sezgisel ve temel olanıdır.

Bir modelin yanlışken yanlış olarak, doğruyken doğru olarak sınıflandırabildiği veri sayısının toplam veri sayısına oranı toplam doğruluk değerini vermektedir.

$$toplam\ doğruluk = \frac{DP + DN}{DP + YP + DN + YN}$$

Pozitif yorum gücü (precision), doğru tahmin edilen pozitif gözlem sonuçlarının toplam pozitif tahminlere oranını, negatif yorum gücü ise doğru tahmin edilen negatif gözlem sonuçlarının, toplam negatif tahminlere oranını vermektedir.

$$pozitif\ yorum\ gücü = \frac{DP}{DP + YP}$$

Duyarlılık (recall), modelin hassaslığını ölçmede kullanılır. Doğru tahmin edilen pozitif tahminlerin, gerçekte doğru olan (duman içeren) tüm görsellerin sayısına oranını vermektedir.

$$\text{duyarlılık} = \frac{DP}{DP + YN}$$

F-değerlendirme (f-score), pozitif yorum gücü ve duyarlılık değerlerinin ağırlıklandırılmış oranı sonucu elde edilen bir değerdir. F-değeri hesaplanırken hem yanlış-pozitif hem de yanlış-negatif değerler hesaba katılmaktadır. Sınıfların dağılımı dengeli olmadığında modelin başarısının ölçülmesinde toplam doğruluk ölçütüyle kıyaslandığında daha geçekçi sonuçlar vermektedir.

$$F - \text{değerlendirme} = \frac{2 * \text{duyarlılık} * \text{pozitif yorum gücü}}{\text{duyarlılık} + \text{pozitif yorum gücü}}$$

Özgüllük (specificity), ikili sınıflandırma testlerinde modelin istatistiksel başarısının ölçülmesinde kullanılan ölçütlerden bir diğeridir. Gerçekte doğru olmayan(duman barındırmayan) ve doğru olmayanlar sınıfına yerleştirilen veri sayısının, gerçekte yanlış olan (duman içeren) tüm görsellerin sayısına oranını vermektedir.

$$\text{özgüllük} = \frac{DP}{YP + DN}$$

Her biri duman içirme ve duman içermeme durumuna göre isimlendirilmiş olan resimlerden meydana gelen kontrol grubu üzerinde yürütülen dört modelin toplam doğruluk, pozitif yorum gücü, negatif yorum gücü, duyarlılık, F-değerlendirme ve özgüllük sonuçları hesaplanmış ve model değerlendirme tablosunda (Çizelge 5.4) verilmiştir. Modellerin tahmin gücünün değerlendirilmesinde kullanılan ölçütlerden hareketle, dört model içinde, doğruluk oranı, f-değeri ve pozitif yorum gücü bakımından tahmin oranı en yüksek modelin M₃ olduğu gözlemlendi.

Çizelge 5.4 Kontrol Grubu Üzerinde Yürütülen Dört Modelin Karşılaştırılması

Değerlendirme Ölçütü	M ₁	M ₂	M ₃	M ₄
Toplam Doğruluk	11/20	11/20	17/20	14/20
Özgüllük	7/10	1/10	7/10	7/10
Duyarlılık	4/10	10/10	10/10	7/10
F-değerlendirme	8/17	20/29	20/23	1/5
Pozitif Yorum Gücü	4/7	10/19	10/13	7/10
Negatif Yorum Gücü	7/13	1	1	7/10

Negatif yorum gücü ve duyarlılığı en güçlü olan iki modelin eşit oranla M₂ ve M₃, özgüllük bakımından en güçlü modellerin ise M₁ ve M₃ olduğu gözlemlendi. Tüm ölçütlerde, en başarılı modelin %70 eğitim ve %30 test verisi ile eğitilmiş M₃ modelinin olduğu saptanmıştır. Modellerin tahmin gücünü karşılaştırmada kullanılan İşlem Karakteristik Eğrisi (ROC, Receiver Operating Characteristics) Analizi adı verilen değerlendirme yöntemi kullanılarak, modelin duyarlılık ve özgüllük oranlarını eksen kabul eden bir grafik oluşturulmasına dayanan bir yöntem mevcuttur. Tez çalışmasında eğitilen modellerin birbiri ile kıyaslandığında ne derece başarılı sonuçlar vermiş olduğu İşlem Karakteristik Eğrisi (ROC, Receiver Operating Characteristics) Analizi ile de ayrıca incelenmiştir. Sonuç olarak yine %70 eğitim ve %30 test verilerinden meydana gelen veri kümesi ile eğitilmiş olan üçüncü modelin en başarılı model olduğu sonucuna varılmıştır.

İşlem karakteristik eğrisi analizinde kelimenin tam anlamıyla bir eğri oluşması için, aynı modelden alınan sürekli verinin bir arada değerlendirilmesi gerekir. Oysa projede aynı modelin birden fazla tahmin ölçüm değeri bulunmamakla birlikte dört ayrı modelin birbiri ile ilişkisi irdelenmektedir. Bu durumda, analiz sonucu ortaya çıkan noktaların altında kalan alan, en doğru ölçüm sonucunu verecektir. İşlem karakteristik eğrisi analizinde kelimenin tam anlamıyla bir eğri oluşması için, aynı modelden alınan sürekli verinin bir arada değerlendirilmesi gerekir. Oysa projede aynı modelin birden fazla tahmin ölçüm değeri bulunmamakla birlikte dört ayrı modelin birbiri ile ilişkisi irdelenmektedir. Bu durumda, analiz sonucu ortaya çıkan noktaların altında kalan alan, en doğru ölçüm sonucunu verecektir. Böyle bakıldığında da, yine M₃ modelinin tahmin başarısı bakımından en iyi model olduğu kabul edilebilir.

M₃ modeli Raspberry Pi'ye yüklenerek test çalışmaları yürütülmüştür. Uçuş testinin, kurallara uygun gerçekleştirilmesi için, Kızılcahamam Soğuksu Mili Parkı yakınlarında, insanlardan uzak ve korunaklı bir bölge tercih edilmiş, test uçuşu ve ilgili çekimler gün ışığından faydalanılarak gerçekleştirilmiştir. Duman kaynağı olarak ise, ayaklı emaye mangal içinde mangal jeli ile tutuşturulmuş, çalı çırpı ve dumanın hacimlenmesi için bir miktar plastik atık malzeme eklenmiştir.



Şekil 5.11 Test Uçuşundan Bir Kare


Sistemin test uçuşu (Şekil 5.11 ve Şekil 5.12) sırasında hem Raspberry içinden (Şekil 5.13), hem de dışarıdan dumanın ve aracın görüntüleri alınmıştır. Araçta, pilotun araca daha rahat hakim olmasına yarayabilecek bir görüş sistemi (FPV, First Person View) bulunmadığından, araç içinden alınan görüntülerde dumanı ortalamak çok zor olmuştur. Bu nedenle benzer projelerde, sürüş sırasında bir görüş desteği kullanılması tavsiye edilmektedir.



Şekil 5.12 Test Uçuşunda Pilot Aracın Bakış Açısını Ayarlamaya Çalışıyor

Bunun yanısıra titreşimden dolayı görüntüler oldukça bulanık ve karmaşık görünmektedir. Buna rağmen, duman tanıma modeli kusursuz çalışmış, ihmal edilebilir

düzeyde lokalizasyon hatası gözlemlenmesine ve benzerlik oranı her duman girdisinde aynı oranda başarı gösterememiş olsa dahi, proje test uçuşu başarılı sonuçlarla sonlandırılmıştır. İnsansız hava aracı uçuşu sırasında, araca VNC yöntemi ile bağlanılarak, Raspberry üzerinden yürütülen proje uygulaması sonucunda, çoğu karede duman görseli başarıyla tanınmış, alınan ekran görüntüleri kaydedilmiştir.



Şekil 5.13 Hareket Halindeki Araca Entegre Çalışan Raspberry Cihazında Gerçek Zamanlı Video Girdisi Üzerinde Yürütülen Duman Tanıma Modelinin Çıktı Görüntüleri

Tercih edilen model, başarıyla görevini icra etmiştir. Bu sonuçlardan hareketle, tasarlanan insansız hava aracı ile erken yangın algılama sisteminin, orman yangınlarının tespitinde kullanılması uygun görülmüştür. Sistemi iyileştirmek adına, insansız hava aracının azami uçuş süresi artırılmaya çalışılabilir böylelikle tek uçuşta kontrol edilebilecek alan genişletilebilir. Doğa dostu bu projedeki sistemin, LiPo batarya yerine güneş enerjisi gibi dönüştürülebilir enerji kaynaklarından beslenmesi sağlanabilir. Bunun yanı sıra, insansız hava aracında dumanın algılandığı durumlarda, monoküler derinlik algılama algoritmaları (Boroujeni 2013) (Zhang 2015) ile dumanın araçtan ne kadar uzakta

olduğunun tahmin edilmesi ve bu iyileştirme sayesinde, yangının çıktığı konumun yer istasyonuna bildirilmesi mümkün kılınabilir.

Duman tanıma uygulamasına ek olarak aynı model, alev ve ateş görsellerini de algılamak üzere eğitilebilir ve insansız hava aracına aşağı doğru bakan bir kamera daha eklenerek, duman tespit edilen bölgenin üzerinde askıda duran araçta aşağı doğru ateş/alev taraması gerçekleştirilebilir. Bu sağlama aşaması, projenin sonucunun doğruluğunu pekiştirecektir. Aracın gövdesinin üç boyutlu teknik çizimlerine ve elektronik devre şemasına (Ek 3) “Ekler” bölümünden ulaşılabilir. Projenin, benzer bilimsel çalışmalara ışık tutması dileğiyle, proje başarıyla sonlandırılmıştır.

KAYNAKLAR

- Akyürek, S., Yılmaz, M.A., ve Taşkıran, M. (2012). İnsansız hava araçları Muharebe alanında ve terörle mücadelede devrimsel dönüşüm, Bilgesam Yayınları, Rapor No:53. Ankara.
- Boroujeni, N. S. (2019). Monocular vision system for unmanned aerial vehicles. doi:10.22215/etd/2013-07242
- Cazzolato, M. T., Avalhais, L. P., Chino, D. Y., Ramos, J. S., De Souza, J. A., & Rodrigues-Jr, J. F. (2017). FiSmo: A Compilation of Datasets from Emergency Situations for Fire and Smoke Anal. Retrieved from http://conteudo.icmc.usp.br/pessoas/junio/PublishedPapers/Cazzolato_et_al_SBBD2017.pdf
- Celik, T. (2010). Fast and Efficient Method for Fire Detection Using Image Processing. *ETRI Journal*, 32(6), 881-890. doi:10.4218/etrij.10.0109.0695
- Chang, C.(2013). Three-Dimensional Receiver Operating Characteristics(3D ROC) Analysis. *Hyperspectral Data Processing*, 63-100. doi:10.1002/9781118269787.ch3
- Chen, T., Wu, P., & Chiou, Y. (2014). An early fire-detection method based on image processing. *2004 International Conference on Image Processing, 2004. ICIP 04*.doi:10.1109/icip.2004.1421401
- Deep Learning in Python: Introduction to Deep Learning. (2019). doi:10.4135/9781526493446
- Deep Learning with Tensorflow. (2017). Retrieved from <https://www.udemy.com/deep-learning-with-Tensorflow/>
- Gad, A. F. (2018). Tensorflow Recognition Application. *Practical Computer Vision Applications Using Deep Learning with CNNs*, 229-294. doi:10.1007/978-1-4842-4167-7_6
- Gao, Y., & Cheng, P. (2019). Forest Fire Smoke Detection Based on Visual Smoke Root and Diffusion Model. *Fire Technology*. doi:10.1007/s10694-019-00831-x
- Habiboglu, H., Gunay, O., Cetin, A., (2011). Real-time wildfire detection using correlation descriptors. Retrieved from https://www.researchgate.net/publication/266070837_Real-time_wildfire_detection_using_correlation_descriptors

- Historical Aspects of Unmanned Aerial Vehicles. (2016). *Theory, Design, and Applications of Unmanned Aerial Vehicles*, 1-45. doi:10.1201/9781315371191-2
- How to Install Raspbian on Your Raspberry Pi SD Card. (2018, December 06). Retrieved from <https://extratechtalk.in/how-to-install-raspbian-on-your-Raspberry-pi-sd-card/>
- Interfacing to the Raspberry Pi Input/Outputs. (2016). *Exploring Raspberry Pi*, 217-273. doi:10.1002/9781119211051.ch6
- Joseph, A., & Geetha, P. (2019). Facial emotion detection using modified eyemap-mouthmap algorithm on an enhanced image and classification with Tensorflow. *The Visual Computer*. doi:10.1007/s00371-019-01628-3
- Ketkar, N. (2017). Training Deep Learning Models. *Deep Learning with Python*, 215-222. doi:10.1007/978-1-4842-2766-4_14
- Kurniawan, A. (2018). Programming on Raspbian OS. *Raspbian OS Programming with the Raspberry Pi*, 79-96. doi:10.1007/978-1-4842-4212-4_3
- Learning Object Model For Moving Foreground Object Detection Using Regression Method. (2017). *International Journal of Recent Trends in Engineering and Research*, 3(3), 209-212. doi:10.23883/ijrter.conf.20170331.041.oehos
- Lei, T., & Sewchand, W. (2002). Object detection and recognition via stochastic model-based image segmentation. *Sixth Multidimensional Signal Processing Workshop*. doi:10.1109/mdsp.1989.96994
- Lei, W., & Liu, J. (2013). Early Fire Detection in Coalmine Based on Video Processing. *Proceedings of the 2012 International Conference on Communication, Electronics and Automation Engineering Advances in Intelligent Systems and Computing*, 239-245. doi:10.1007/978-3-642-31698-2_35
- Lin, G., Zhang, Y., Zhang, Q., Jia, Y., Xu, G., & Wang, J. (2017, November 30). Smoke detection in video sequences based on dynamic texture using volume local binary patterns. Retrieved from <http://www.itiiis.org/digital-library/manuscript/1855>
- Lum, C. W., Summers, A., Carpenter, B., Rodriguez, A., & Dunbabin, M. (2015). Automatic Wildfire Detection and Simulation using Optical Information from Unmanned Aerial Systems. *SAE Technical Paper Series*. doi:10.4271/2015-01-2474
- Merino, L., Dios, J. R., & Ollero, A. (2014). Cooperative Unmanned Aerial Systems for Fire Detection, Monitoring, and Extinguishing. *Handbook of Unmanned Aerial Vehicles*, 2693-2722. doi:10.1007/978-90-481-9707-1_74


- Meyer, J., Du, F., & Clarke, W. (2009). Design Considerations for Long Endurance Unmanned Aerial Vehicles. *Aerial Vehicles*. doi:10.5772/6482
- Object Detection and Tracking with OpenCV and Python ... (2017). Retrieved from <https://www.bluetin.io/OpenCV/object-detection-tracking-OpenCV-python/>
- Patel, P., & Tiwari, S. (2012). Flame Detection using Image Processing Techniques. *International Journal of Computer Applications*, 58(18), 13-16. doi:10.5120/9381-3817
- Pattanayak, S. (2017). Introduction to Deep-Learning Concepts and Tensorflow. *Pro Deep Learning with Tensorflow*, 89-152. doi:10.1007/978-1-4842-3096-1_2
- Perlich, C. (2017). Learning Curves in Machine Learning. *Encyclopedia of Machine Learning and Data Mining*, 708-711. doi:10.1007/978-1-4899-7687-1_452
- Ranftl, R., Vineet, V., Chen, Q., & Koltun, V. (2016). Dense Monocular Depth Estimation in Complex Dynamic Scenes. *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. doi:10.1109/cvpr.2016.440
- Santana, P., Gomes, P., & Barata, J. (2012). A vision-based system for early fire detection. *2012 IEEE International Conference on Systems, Man, and Cybernetics (SMC)*. doi:10.1109/icsmc.2012.6377815
- Seebamrungsat, J., Praising, S., & Riyamongkol, P. (2014). Fire detection in the buildings using image processing. *2014 Third ICT International Student Project Conference (ICT-ISPC)*. doi:10.1109/ict-ispc.2014.6923226
- Shaikh, F. (2018, July 13). Understanding and Building an Object Detection Model from Scratch in Python. Retrieved from <https://www.analyticsvidhya.com/blog/2018/06/understanding-building-object-detection-model-python/>
- Shaqura, M., & Shamma, J. S. (2017). An Automated Quadcopter CAD based Design and Modeling Platform using Solidworks API and Smart Dynamic Assembly. *Proceedings of the 14th International Conference on Informatics in Control, Automation and Robotics*. doi:10.5220/0006438601220131
- Sharma, V. A., & Rajesh, M. (2018). Building a quadcopter: An approach for an Autonomous Quadcopter. *2018 International Conference on Advances in Computing, Communications and Informatics (ICACCI)*. doi:10.1109/icacsi.2018.8554718
- Smoke detection in video sequences based on dynamic texture using volume local binary patterns. (2017). *KSII Transactions on Internet and Information Systems*, 11(11). doi:10.3837/tiis.2017.11.019

- Spy your pet with a Raspberry Pi Camera Server. (2017). Retrieved from <https://hackernoon.com/spy-your-pet-with-a-Raspberry-pi-camera-server-e71bb74f79ea>
- Süleyman, Güdükbay, Uğur, B., & Enis, A. (2019, February 05). Deep Convolutional Generative Adversarial Networks Based Flame Detection in Video. Retrieved from <https://arxiv.org/abs/1902.01824>
- Tensorflow. (2019, July 15). Tensorflow/models. Retrieved from https://github.com/Tensorflow/models/tree/master/research/object_detection
- Tensorflow : Tensorflow. (2019). Retrieved from <https://www.Tensorflow.org/>
- Tensorflow: A System for Large-Scale Machine Learning. (2016). Retrieved from <https://www.usenix.org/system/files/conference/osdi16/osdi16-abadi.pdf>
- Toreyin, B. U., & Cetin, A. E. (2009). Wildfire detection using LMS based active learning. *2009 IEEE International Conference on Acoustics, Speech and Signal Processing*. doi:10.1109/icassp.2009.4959870
- Toreyin, B., Dedeoglu, Y., & Cetin, A. (2005). Flame detection in video using hidden Markov models. *IEEE International Conference on Image Processing 2005*. doi:10.1109/icip.2005.1530284
- Tyagi, V. (2018). Introduction to Digital Image Processing. *Understanding Digital Image Processing*, 1-12. doi:10.1201/9781315123905-1
- Video Smoke Detection using Deep Domain Adaptation ... (2017). Retrieved from <https://www.nfpa.org/-/media/Files/News-and-Research/Resources/Research-Foundation/Symposia/2017-SUPDET/SUPDET17-Xu-Gao-et-al.ashx?la=en&hash=564B572F6CCF257AC895D228F57D204F21708577>
- Wang, T., Liu, Y., & Xie, Z. (2011). Flutter Analysis Based Video Smoke Detection. *Journal of Electronics & Information Technology*, 33(5), 1024-1029. doi:10.3724/sp.j.1146.2010.00912
- Wang, W., & Zhou, H. (2012). Fire detection based on flame color and area. *2012 IEEE International Conference on Computer Science and Automation Engineering (CSAE)*. doi:10.1109/csae.2012.6272943
- Wang, Z., Wang, Z., Zhang, H., & Guo, X. (2017). A Novel Fire Detection Approach Based on CNN-SVM Using Tensorflow. *Intelligent Computing Methodologies Lecture Notes in Computer Science*, 682-693. doi:10.1007/978-3-319-63315-2_60
- Wildfire Smoke Detection using Convolutional Neural Networks. (2015). Retrieved from http://www.inf.fu-berlin.de/inst/ag-ki/rojas_home/documents/Betreute_Arbeiten/Master-Hohberg.pdf

- Xeriansyah, R. (2007). Defect Detection in Thermal Image using Thresholding Technique. Retrieved from https://www.academia.edu/8879203/Defect_Detection_in_Thermal_Image_using_Thresholding_Technique
- Xu, G., Zhang, Y., Zhang, Q., Lin, G., & Wang, J. (2017). Deep domain adaptation based video smoke detection using synthetic smoke images. *Fire Safety Journal*, 93, 53-59. doi:10.1016/j.firesaf.2017.08.004
- Zhang, F. (2015). Obstacle Detection Using Monocular Camera for Low Flying Unmanned Aerial Vehicle. doi:10.22215/etd/2015-10769
- Zhang, Q., Lin, G., Zhang, Y., Xu, G., & Wang, J. (2018). Wildland Forest Fire Smoke Detection Based on Faster R-CNN using Synthetic Smoke Images. *Procedia Engineering*, 211, 441-446. doi:10.1016/j.proeng.2017.12.034
- Zhou, B., Song, Y., & Yu, M. (2015). Video Fire Smoke Detection Based on Static Features of Smoke. *Journal of Advanced Computing*

AKS BELİRTİLMEDİĞİ SÖZÜMÜ: BOYUTLAR MİLMİMETREDİR YÜZEY CİLASI: TOLERANSLAR: DOKURUSAL AÇISAL		SİTİRİVE:		KESEİN KENARLAR PANKLAYN VE KORIN		TEKNİK RESİM ÇİZİMİNDİR		REVİZYON	
ÇİZEN	İSM	KİZA	TARİH			BAŞLIK:			
ÇİZEN									
ONAY									
ÇİZEN									
KADE									
MALZEME:						RESİM NO:		A3	
AĞIRLIK:						ÇİZİM NO:		SAYFA 1 / 1	

75



Ek 2 İnsansız Hava Aracının Üst Gövdesinin Teknik Çizimi

ÖZGEÇMİŞ

Adı Soyadı :

Doğum Yeri :

Doğum Tarihi :

Yabancı Dili :

Eğitim Durumu (Kurum ve Yıl)

Lise :

Lisans :

Yüksek Lisans:

Çalıştığı Kurum (Kurum ve Yılı)

Yayınlar